

Meilenstein 1: Problemverständnis, Data Understanding und Baseline

Domänenprojekt 2 – Kultur- und Entwicklungsstadiumsklassifikation

Team: Æ-RØØT

Mitglieder: Pascal Heinzemann, Achim Duong, Jan-David Wiederstein

Stand: 06.10.2026

Code-Version: *[Commit oder Branch ergänzen]*

1 Domäne und Ziel

1.1 Fachlicher Kontext

Die Aufgabenbeschreibung behandelt satellitengestützte Hyperspektralaufnahmen landwirtschaftlicher Flächen in den USA. EO-1 Hyperion erfasst Reflexion in vielen schmalen Spektralkanälen von ungefähr 10 nm Breite. Die Aufgabenfolien beschreiben jede Beobachtung als ein Feld und nennen eine räumliche Auflösung von 30 m. Im bereitgestellten Datensatz entspricht eine Zeile einem Spektrum; ob jede Zeile unverändert genau einem Originalpixel entspricht, ist anhand der Tabellendaten allein nicht nachprüfbar.

Neben den Spektralbändern enthält der Datensatz **AEZ** und **Month**. Laut Aufgabenbeschreibung fassen agroökologische Zonen Gebiete mit ähnlichen natürlichen Anbaubedingungen zusammen, unter anderem Klima, Böden und Vegetationsperiode. Diese Angaben sind möglicher zusätzlicher Kontext für die Klassifikation; ihre Verfügbarkeit und Aussagekraft für spätere, neue Daten muss bei der Bewertung berücksichtigt werden.

1.2 Projektziel und fachliche Relevanz

Das Projektziel ist die zuverlässige Klassifikation der Kulturpflanze (**Crop**) und ihres Entwicklungsstadiums (**Stage**) anhand der spektralen Signaturen aus EO-1-Hyperion-Aufnahmen. Die Aufgabenbeschreibung formuliert den Zielansatz hierarchisch: zuerst die Kulturpflanzenart, dann das Entwicklungsstadium innerhalb der vorhergesagten Kulturklasse. Andere Strategien – beispielsweise kombinierte Crop-Stage-Klassen oder getrennte Modelle – sind ebenfalls zulässig, sofern sie begründet und miteinander verglichen werden.

Die Aufgabenbeschreibung begründet die Relevanz mit der landwirtschaftlichen Bestandsaufnahme, der Planung von Bewirtschaftungsmaßnahmen sowie der Erstellung präziserer Modelle, Karten und Überwachungsmöglichkeiten. Satellitenbeobachtungen können eine großflächige Klassifikation ermöglichen, ohne jeden Standort einzeln aufsuchen zu müssen. Das Projekt prüft die Klassifikationsleistung auf den bereitgestellten Daten; es weist nicht nach, dass eine konkrete Bewirtschaftungsentscheidung dadurch verbessert wird.

1.3 Untersuchungs- und Bewertungsziel

Neben der Entwicklung eines Klassifikators verlangt die Aufgabenbeschreibung den Vergleich unterschiedlicher Modellierungsstrategien und die Untersuchung, ob sich die Eingabedaten durch Dimensionsreduktion verringern lassen, ohne die Klassifikationsleistung zu verschlechtern. Bewertet werden sowohl **Crop** als auch **Stage**. Wegen der ungleichen Klassenverteilung nennt die Aufgabenbeschreibung Balanced Accuracy und Macro-F1 als zentrale Metriken; Sample-F1 ist eine weitere Projektmetrikt. Ergebnisse sollen für beide Zielgrößen und mit Blick auf die Klassenverteilung interpretiert werden.

2 Data Understanding

2.1 Umfang und Merkmale

Tabelle 1: Umfang und verfügbare Merkmale der Datensätze

Datensatz	Beobachtungen	Zielwerte	Eingaben
Training	5.591	Crop, Stage	Spektralbänder, AEZ, Month
Test	1.397	nicht vorhanden	Spektralbänder, AEZ, Month

Die Tabelle enthält 198 Spektralspalten mit Wellenlängen von 427 bis 2.395 nm. In beiden Datensätzen sind dieselben 67 Bänder vollständig leer; 131 Bänder enthalten Messwerte. In sechs weiteren verfügbaren Bändern fehlen einzelne Werte, insgesamt sind davon 44 Trainings- und 11 Testzeilen betroffen.

2.2 Labelverteilung und spektrale Muster

Die Labels sind unausgewogen: **rice** umfasst 93 Trainingsbeobachtungen, gegenüber 2.097 bei **corn**; **Harvest** ist mit 180 Beobachtungen das seltenste Stadium, während **Critical** mit 1.541 am häufigsten vorkommt. Bei den Crop-Stage-Paaren reicht die Häufigkeit von 11 Beobachtungen für **cotton** $\times$ **Harvest** bis 675 für **corn** $\times$ **Critical**. Insgesamt kommen 23 der 30 möglichen Kombinationen im Training vor. Die nicht beobachteten Kombinationen sind ein Befund zur Stichprobe und belegen nicht, dass diese Kombinationen fachlich unmöglich sind.

Die mittleren Spektren unterscheiden sich zwischen Kulturen und teilweise zwischen Stadien innerhalb einer Kultur. Die Streuung und Überlappung zwischen Gruppen bleibt sichtbar; die Spektren trennen die Zielklassen daher nicht vollständig. Benachbarte verfügbare Bänder sind stark korreliert. **AEZ** und **Month** hängen ebenfalls mit der Labelverteilung zusammen. Beispielsweise ist **Month** 8 bei **corn** im Training nur mit **Critical** vertreten. Diese Muster motivieren Modellvarianten, belegen aber keine Vorhersageleistung.

2.3 Datenqualität, Ausreißer und Ähnlichkeit

Im Training wurden zwei Paare identischer Eingaben mit übereinstimmenden Labels gefunden. Zwischen vollständigen Train- und Test-Spektren der verfügbaren Bänder wurden keine exakten Treffer festgestellt. Der explorative Similarity-Screen fand innerhalb derselben Crop-Stage-Gruppe viele Paare mit hoher Cosinus-Ähnlichkeit. Da die verwendete Schwelle nicht als Duplikatgrenze validiert ist und Feld- oder Aufnahme-IDs fehlen, belegt das weder Duplikate noch gemeinsame Flächen oder Leakage.




Abbildung 1: Häufigkeit der beobachteten Crop-Stage-Kombinationen.




Abbildung 2: Mittlere Spektralsignaturen nach Crop; Unterschiede und Überlappungen zeigen, wie trennbar die Kulturen anhand der Spektren erscheinen.

Mittlere Spektralsignatur ± 1 Standardabweichung nach Stage innerhalb jedes Crop




Abbildung 3: Mittlere Stadien-Spektren innerhalb jeder Crop-Klasse; Streuung und Überlappung veranschaulichen die Schwierigkeit der Stage-Vorhersage.




Abbildung 4: Stage-Häufigkeiten nach Month innerhalb jeder Crop-Klasse; die Verteilung zeigt den Zusammenhang zwischen Kontextmerkmalen und Labels.

Die Ausreißer- und Sprungdiagnostik markiert Kandidaten zur Prüfung, bestätigt aber keine fehlerhaften Messungen. Insbesondere die verfügbaren Bänder X912, X915 und X923 werden nicht allein wegen ihrer Lage oder eines lokalen Kurvenverlaufs entfernt. Eine technische oder biologische Ursache der dortigen Auffälligkeiten ist anhand der vorliegenden Angaben nicht belegt.

2.4 Grenzen der Datengrundlage

Feld-, Bild- oder räumliche Gruppenkennungen liegen in der verwendeten Tabelle nicht vor. Deshalb lässt sich nicht feststellen, ob ähnlich erscheinende Spektren abhängige Beobachtungen sind. Auch die technische Ursache vollständig leerer Bänder und die genaue Vorverarbeitung vor Bereitstellung des Datensatzes sind nicht abschließend dokumentiert. Die mögliche Übertragbarkeit auf andere Regionen, Jahre oder Aufnahmebedingungen wird mit diesem Holdout-Split nicht belegt.

3 Erste Data-Preprocessing-Pipeline

3.1 Pipeline-Ablauf

[Wird von der zuständigen Person ergänzt.]

3.2 Cleaning- und Preprocessing-Entscheidungen

Die folgenden Empfehlungen stützen sich auf die explorative Datenanalyse. Sie unterscheiden zwischen unmittelbar begründeten Bereinigungen und Varianten, deren Nutzen erst in einer sauberen Validierung geprüft werden muss.

Tabelle 2: Cleaning- und Preprocessing-Empfehlungen aus der EDA.

Thema	Empfehlung	Begründung
Vollständig leere Bänder	Die 67 vollständig leeren Bänder aus den Modellmerkmalen entfernen; die 131 verfügbaren zunächst als Rohband-Baseline behalten.	Leere Spalten enthalten keine Messinformation. Die Ursache ihres Fehlens ist nicht belegt. Die verfügbaren Bänder X912, X915 und X923 nicht allein wegen ihrer Nähe zu leeren Bändern entfernen.
Fehlende Einzelwerte	Verbleibende Lücken innerhalb eines Spektrums interpolieren und Randlücken mit dem nächstgelegenen vorhandenen Wert behandeln. Die Imputation innerhalb der Modellpipeline durchführen.	Es fehlen einzelne Bandwerte in wenigen Zeilen. Die Vorverarbeitung muss innerhalb jedes Trainingsfolds angepasst werden, damit keine Validierungsinformation einfließt.
Glättung	Keine Glättung als Standard-Cleaning einführen. Falls begründet, wenige vorab festgelegte Varianten als eigene Modellvarianten in der Cross-Validation vergleichen (Meilenstein 2).	Lokale Sprung- oder Unruhekanidaten belegen keinen allgemeinen Glättungsbedarf. Glättung könnte auch informative spektrale Unterschiede abschwächen.
Ausreißer	Isolation-Forest- und klassenweise Mahalanobis-Scores zum Markieren und Prüfen verwenden; Zeilen nicht allein aufgrund eines Scores automatisch löschen.	Ein hoher Score beweist keinen Messfehler. Besonders Mahalanobis-Abstände sind bei vielen Bändern und kleinen Crop-Stage-Gruppen vorsichtig zu interpretieren.
Exakte Duplikate	Die zwei identischen Trainingspaare vor dem Split deduplizieren, sofern die Labels übereinstimmen. Near-Duplicates nicht anhand eines frei gewählten Schwellenwerts löschen.	Exakte Wiederholungen könnten sonst auf verschiedene Split-Teile geraten. Spektralähnlichkeit allein beweist weder fehlerhafte Daten noch dieselbe Beobachtungsquelle.
Ähnliche Spektren / Leakage	Ähnlichkeit als Prüfhypothese dokumentieren. Falls Feld-, Bild- oder Aufnahme-IDs verfügbar sind, abhängige Beobachtungen gemeinsam splitten.	Innerhalb einer Klasse zeigen ähnliche Spektren zunächst mögliche Redundanz. Abhängige Messungen auf beiden Seiten der Split-Grenze könnten die Evaluation optimistisch machen; die vorhandenen Daten belegen eine solche Abhängigkeit nicht.
Split und Evaluation	Den kombinierten Crop-Stage-Label beim stratifizierten Split berücksichtigen und Cross-Validation nur auf dem Trainingsanteil durchführen. Balanced Accuracy und Macro-F1 jeweils für Crop und Stage berichten.	Die Klassen sind unausgewogen und das kleinste beobachtete Paar umfasst 11 Zeilen. Stratifizierung hilft, seltene Paare zu erhalten, garantiert aber keine räumlich unabhängige Evaluation.
AEZ und Month	Varianten mit und ohne Kontextmerkmale vergleichen.	Die Merkmale hängen mit der Labelverteilung zusammen; ihre Verfügbarkeit und Stabilität beim späteren Einsatz sind gesondert zu klären.

4 Erster Baseline-Klassifikator

4.1 70/30 Clusterplot-Split

[Tatsächlich verwendete Split-Methode und Klärung des Begriffs „Clusterplot-Split“ ergänzen.]

4.2 Modell und Code

[Modell, Merkmale, Einstellungen und Code-Einstiegspunkt ergänzen.]

4.3 Kurzer Demo-Run

[Ausführungsbefehl, Demo-Ablauf und erzeugte Ausgabe ergänzen.]

4.4 Ergebnisse und kurze Einordnung

[Metriken für Crop und Stage, Vergleichsreferenz und wichtigste Beobachtungen ergänzen.]

5 Fazit, offene Punkte und nächste Schritte

5.1 Ergebnis von Meilenstein 1

- Domänenziel und Grenzen der Vorhersage sind beschrieben.
- Datenumfang, Labelungleichgewicht, fehlende Bänder und sichtbare spektrale Überlappungen wurden untersucht.
- Pipeline und Baseline werden in den dafür vorgesehenen Abschnitten dokumentiert.

5.2 Offene Punkte

- Bedeutung des geforderten „70/30 Clusterplot-Splits“ klären.
- Verfügbarkeit von Feld-, Bild- oder räumlichen IDs sowie die Bedeutung von Month und AEZ klären.
- Herkunft und Vorverarbeitung der Spektralbänder klären.

5.3 Nächste Schritte

- Die Pipeline- und Baseline-Abschnitte nach den jeweiligen Demo-Läufen vervollständigen.
- Modelle mit und ohne AEZ und Month sowie begründete Glättungs- oder Merkmalsreduktionsvarianten innerhalb derselben Cross-Validation vergleichen.

6 Quellen im Projekt

- Domänenbeschreibung: `../domaene/index.md`
- Data Understanding und EDA: `../daten/m1-data-understanding.md`
- Vollständige EDA-Dokumentation: `../daten/eda.md`
- Datenpipeline: `../daten/pipeline.md`
- Baseline-Ergebnisse: `../modelle/ansaetze/baseline.md`
- Offene Fragen an die Betreuung: `offene-fragen.md`