

# Meilenstein 1: Problemverständnis, Data Understanding und Baseline

Domänenprojekt 2 – Kultur- und Entwicklungsstadiumsklassifikation

Team: Æ-RØØT

Mitglieder: Achim Duong, Pascal Heinzelmann, Jan-David Wiederstein

Stand: 06.10.2026

Code-Version: Branch `main`, Pipeline-Code (`src/awp2`) Stand Commit `a43ef23`

## 1 Domäne und Ziel

### 1.1 Fachlicher Kontext

Die Aufgabenbeschreibung behandelt satellitengestützte Hyperspektralaufnahmen landwirtschaftlicher Flächen in den USA. EO-1 Hyperion erfasst Reflexion in vielen schmalen Spektralkanälen von ungefähr 10 nm Breite; ein Pixel deckt eine Fläche von  $30\text{ m} \times 30\text{ m}$  ab. Im bereitgestellten Datensatz entspricht eine Zeile einem Spektrum; ob jede Zeile unverändert genau einem Originalpixel entspricht, ist anhand der Tabellendaten allein nicht nachprüfbar.

Neben den Spektralbändern enthält der Datensatz `AEZ` und `Month`. Agro-ökologische Zonen (AEZ) fassen Gebiete mit ähnlichen natürlichen Anbaubedingungen zusammen, unter anderem Klima, Böden und Vegetationsperiode.

### 1.2 Projektziel und fachliche Relevanz

Das Projektziel ist die zuverlässige Klassifikation der Kulturpflanze (`Crop`) und ihres Entwicklungsstadiums (`Stage`) anhand der spektralen Signaturen aus EO-1-Hyperion-Aufnahmen.

Die Aufgabenbeschreibung begründet die Relevanz mit der landwirtschaftlichen Bestandsaufnahme, der Planung von Bewirtschaftungsmaßnahmen sowie der Erstellung präziserer Modelle, Karten und Überwachungsmöglichkeiten. Satellitenbeobachtungen können eine großflächige Klassifikation ermöglichen, ohne jeden Standort einzeln aufsuchen zu müssen. Das Projekt prüft die Klassifikationsleistung auf den bereitgestellten Daten; es weist nicht nach, dass eine konkrete Bewirtschaftungsentscheidung dadurch verbessert wird.

### 1.3 Untersuchungs- und Bewertungsziel

Neben der Entwicklung eines Klassifikators verlangt die Aufgabenbeschreibung den Vergleich unterschiedlicher Modellierungsstrategien und die Untersuchung, ob sich die Eingabedaten durch Dimensionsreduktion verringern lassen, ohne die Klassifikationsleistung zu verschlechtern. Bewertet werden sowohl `Crop` als auch `Stage`. Wegen der ungleichen Klassenverteilung nennt die Aufgabenbeschreibung Balanced Accuracy und Macro-F1 als zentrale Metriken; Sample-F1 ist eine weitere Projektmetriken. Ergebnisse sollen für beide Zielgrößen und mit Blick auf die Klassenverteilung interpretiert werden.

## 2 Data Understanding

### 2.1 Umfang und Merkmale


**Tabelle 1:** Umfang und verfügbare Merkmale der Datensätze

| Datensatz | Beobachtungen | Zielwerte       | Eingaben                   |
|-----------|---------------|-----------------|----------------------------|
| Training  | 5.591         | Crop, Stage     | Spektralbänder, AEZ, Month |
| Test      | 1.397         | nicht vorhanden | Spektralbänder, AEZ, Month |

Die Tabelle enthält 198 Spektralspalten mit Wellenlängen von 427 bis 2.395 nm. In beiden Datensätzen sind dieselben 67 Bänder vollständig leer; 131 Bänder enthalten Messwerte. In sechs weiteren verfügbaren Bändern fehlen einzelne Werte, insgesamt sind davon 44 Trainings- und 11 Testzeilen betroffen.


### 2.2 Labelverteilung und spektrale Muster

Die Labels sind unausgewogen: **rice** umfasst 93 Trainingsbeobachtungen, gegenüber 2.097 bei **corn**; **Harvest** ist mit 180 Beobachtungen das seltenste Stadium, während **Critical** mit 1.541 am häufigsten vorkommt. Bei den Crop-Stage-Paaren reicht die Häufigkeit von 11 Beobachtungen für **cotton**  $\times$  **Harvest** bis 675 für **corn**  $\times$  **Critical**. Insgesamt kommen 23 der 30 möglichen Kombinationen im Training vor. Die nicht beobachteten Kombinationen sind ein Befund zur Stichprobe und belegen nicht, dass diese Kombinationen fachlich unmöglich sind.




**Abbildung 1:** Häufigkeit der beobachteten Crop-Stage-Kombinationen.


Die mittleren Spektren unterscheiden sich zwischen Kulturen und teilweise zwischen Stadien innerhalb einer Kultur. Die Streuung und Überlappung zwischen Gruppen bleibt sichtbar; die Spektren trennen die Zielklassen daher nicht vollständig. Benachbarte verfügbare Bänder sind stark korreliert. **AEZ** und **Month** hängen ebenfalls mit der Labelverteilung zusammen. Beispielsweise ist **Month** 8 bei **corn** im Training nur mit **Critical** vertreten. Diese Muster motivieren Modellvarianten, belegen aber keine Vorhersageleistung.



**Abbildung 2:** Mittlere Spektralsignaturen nach Crop; Unterschiede und Überlappungen zeigen, wie trennbar die Kulturen anhand der Spektren erscheinen.



**Abbildung 3:** Mittlere Stadien-Spektren innerhalb jeder Crop-Klasse; Streuung und Überlappung veranschaulichen die Schwierigkeit der Stage-Vorhersage.



**Abbildung 4:** Stage-Häufigkeiten nach Month innerhalb jeder Crop-Klasse; die Verteilung zeigt den Zusammenhang zwischen Kontextmerkmalen und Labels.

## 2.3 Datenqualität, Ausreißer und Ähnlichkeit

Im Training wurden zwei Paare identischer Eingaben mit übereinstimmenden Labels gefunden. Zwischen vollständigen Train- und Test-Spektren der verfügbaren Bänder wurden keine exakten Treffer festgestellt. Der explorative Similarity-Screen fand innerhalb derselben Crop-Stage-Gruppe viele Paare mit hoher Cosinus-Ähnlichkeit, insbesondere bei Mais und Soja.

Die Ausreißer- und Sprungdiagnostik markiert Kandidaten zur Prüfung, die jedoch aufgrund der teils sehr geringen Gruppengrößen nicht automatisch entfernt werden sollten.

## 2.4 Grenzen der Datengrundlage

Feld-, Bild- oder räumliche Gruppenkennungen liegen in der verwendeten Tabelle nicht vor. Deshalb lässt sich nicht feststellen, ob ähnlich erscheinende Spektren abhängige Beobachtungen sind. Auch die technische Ursache vollständig leerer Bänder und die genaue Vorverarbeitung vor Bereitstellung des Datensatzes sind nicht abschließend dokumentiert.

# 3 Erste Data-Preprocessing-Pipeline

## 3.1 Pipeline-Ablauf


Die Pipeline liefert allen Modellierungsansätzen dieselben bereinigten Daten, denselben Split, dieselbe Vorverarbeitung und dieselben Metriken. Ergebnisse verschiedener Ansätze sind dadurch direkt vergleichbar. Das Modell selbst baut jeder Ansatz eigenständig. Die Pipeline arbeitet in zwei Stufen (Abbildung 5):

1. **Datenaufbereitung, einmalig (make data):** Die Rohdaten werden beim Laden gegen ein Schema geprüft (Spalten, Wertebereiche, gültige Labels), die zwei exakt doppelten Zeilen

entfernt und der Split festgelegt (Abschnitt 4.1). Ergebnis sind zwei deterministisch erzeugte und damit bei allen Teammitgliedern identische Dateien: `train_clean.parquet` mit den bereinigten Daten und `split.csv` mit der Zuordnung jeder Zeile zu Train, Holdout und CV-Fold.

2. **Vorverarbeitung, je Modell:** Leere Bänder entfernen, Lücken interpolieren, AEZ als One-Hot-Kodierung, optional Skalierung und Vegetationsindizes. Diese Schritte sind der erste Teil einer sklearn-Pipeline und werden nur auf dem jeweiligen Trainingsteil gelernt. Validierungs- und Testdaten werden mit denselben gelernten Werten transformiert, ohne dass Informationen aus ihnen in das Modell einfließen. Die Vorverarbeitung wird deshalb bewusst nicht als Datei gespeichert.

Gesteuert wird alles über zwei Funktionen: `tune()` sucht Hyperparameter per Cross-Validation auf dem Trainingsteil, `run()` trainiert das gewählte Modell und bewertet es einmal auf dem Holdout. `evaluate()` berechnet dabei Balanced Accuracy und Macro-F1 für Crop, Stage und das kombinierte Paar, den Samples-F1 sowie den Anteil ungültiger Crop-Stage-Kombinationen. Jeder Aufruf wird in MLflow protokolliert (Abschnitt 4.5). Vorverarbeitungsoptionen sind Felder einer validierten Konfiguration (`PreprocessingConfig`); neue Schritte werden dort ergänzt statt als Einzelcode in Notebooks.



**Abbildung 5:** Gemeinsame Data Pipeline: Die Datenaufbereitung läuft einmal und ist für alle gleich; Vorverarbeitung und Modell werden je Ansatz nur auf dem Trainingsteil gelernt, jeder Lauf wird in MLflow protokolliert.

### 3.2 Cleaning- und Preprocessing-Entscheidungen

**Tabelle 2:** Cleaning- und Preprocessing-Empfehlungen aus der EDA.

| Thema                       | Empfehlung                                                                                                                                                                                                      | Begründung                                                                                                                                                                                                                                    |
|-----------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Vollständig leere Bänder    | Die 67 vollständig leeren Bänder aus den Modellmerkmalen entfernen; die 131 verfügbaren zunächst als Rohband-Baseline behalten.                                                                                 | Leere Spalten enthalten keine Messinformation. Die Ursache ihres Fehlens ist nicht belegt.                                                                                                                                                    |
| Fehlende Einzelwerte        | Verbleibende Lücken innerhalb eines Spektrums interpolieren und Randlücken mit dem nächstgelegenen vorhandenen Wert behandeln. Die Imputation innerhalb der Modellpipeline durchführen.                         | Es fehlen einzelne Bandwerte in wenigen Zeilen. Die Vorverarbeitung muss innerhalb jedes Trainingsfolds angepasst werden, damit keine Validierungsinformation einfließt.                                                                      |
| Glättung                    | Keine Glättung als Standard-Cleaning einführen. Falls begründet, wenige vorab festgelegte Varianten als eigene Modellvarianten in der Cross-Validation vergleichen (Meilenstein 2).                             | Lokale Sprung- oder Unruhe Kandidaten belegen keinen allgemeinen Glättungsbedarf. Glättung könnte auch informative spektrale Unterschiede abschwächen.                                                                                        |
| Ausreißer                   | Isolation-Forest- und klassenweise Mahalanobis-Scores zum Markieren und Prüfen verwenden; Zeilen nicht allein aufgrund eines Scores automatisch löschen.                                                        | Ein hoher Score beweist keinen Messfehler. Besonders Mahalanobis-Abstände sind bei vielen Bändern und kleinen Crop-Stage-Gruppen vorsichtig zu interpretieren.                                                                                |
| Exakte Duplikate            | Die zwei identischen Trainingspaare vor dem Split deduplizieren, sofern die Labels übereinstimmen. Near-Duplicates nicht anhand eines frei gewählten Schwellenwerts löschen.                                    | Exakte Wiederholungen könnten sonst auf verschiedene Split-Teile geraten. Spektralähnlichkeit allein beweist weder fehlerhafte Daten noch dieselbe Beobachtungsquelle.                                                                        |
| Ähnliche Spektren / Leakage | Ähnlichkeit als Prüfhypothese dokumentieren. Falls Feld-, Bild- oder Aufnahme-IDs verfügbar sind, abhängige Beobachtungen gemeinsam splitten.                                                                   | Innerhalb einer Klasse zeigen ähnliche Spektren zunächst mögliche Redundanz. Abhängige Messungen auf beiden Seiten der Split-Grenze könnten die Evaluation optimistisch machen; die vorhandenen Daten belegen eine solche Abhängigkeit nicht. |
| Split und Evaluation        | Den kombinierten Crop-Stage-Label beim stratifizierten Split berücksichtigen und Cross-Validation nur auf dem Trainingsanteil durchführen. Balanced Accuracy und Macro-F1 jeweils für Crop und Stage berichten. | Die Klassen sind unausgewogen und das kleinste beobachtete Paar umfasst 11 Zeilen. Stratifizierung hilft, seltene Paare zu erhalten, garantiert aber keine räumlich unabhängige Evaluation.                                                   |
| AEZ und Month               | Varianten mit und ohne Kontextmerkmale vergleichen.                                                                                                                                                             | Die Merkmale hängen mit der Labelverteilung zusammen; ihre Verfügbarkeit und Stabilität beim späteren Einsatz sind gesondert zu klären.                                                                                                       |

**Umsetzung in Pipeline v1:** Entfernen leerer Bänder, Interpolation, Deduplizierung, stratifizierter Split und AEZ/Month als abschaltbare Option sind umgesetzt. Glättung, Ausreißerentfernung und ein gruppierter Split sind bewusst nicht Teil der ersten Pipeline; sie folgen bei Bedarf als zusätzliche Konfigurationsoptionen und werden dann per Cross-Validation gegen die Baseline verglichen.

## 4 Erster Baseline-Klassifikator

Die Baseline ist bewusst kein begründeter Modellierungsansatz, sondern die Messlatte für alle weiteren: eine Untergrenze ohne Lernen und ein einfaches Modell, das **Crop** und **Stage** ohne eigene Logik gemeinsam vorhersagt.

### 4.1 Split und Validierungsdesign

Was mit dem geforderten „70/30 Clusterplot-Split“ genau gemeint ist, ist bei der Betreuung angefragt und noch offen. Bis zur Klärung verwenden wir einen festen 70/30-Holdout, stratifiziert nach dem kombinierten Label **Crop|Stage**:

- 3.912 Zeilen Training, 1.677 Zeilen Holdout (nach Entfernen der Duplikate). Die Klassenanteile weichen zwischen beiden Teilen um höchstens 0,05 Prozentpunkte ab; auch das seltenste Paar **cotton|Harvest** ist in beiden Teilen vertreten (8 bzw. 3).
- Hyperparameter werden ausschließlich per fünffacher, ebenfalls stratifizierter Cross-Validation auf dem Trainingsteil gewählt. Der Holdout wird je Modell genau einmal zur abschließenden Bewertung genutzt, damit sein Score nicht durch wiederholtes Nachjustieren zu optimistisch wird.
- Ohne Feld- oder Bildkennungen ist kein räumlich gruppierter Split möglich. Ähnliche Spektren können daher auf beiden Seiten des Splits liegen; die Scores sind in dieser Hinsicht eher eine Obergrenze.

### 4.2 Modelle und Einstellungen

- **Dummy**: sagt immer die häufigste Kultur und das häufigste Stadium vorher und markiert damit das Zufallsniveau.
- **Random Forest**: 300 Bäume, `class_weight="balanced"` gegen das Klassenungleichgewicht; sagt beide Zielgrößen nativ gemeinsam vorher. Eingaben sind die 131 verfügbaren Bänder, AEZ (One-Hot) und Month, ohne Skalierung. Gesucht wurden 8 Kombinationen aus `max_depth` {unbegrenzt, 20}, `min_samples_leaf` {1, 3} und `max_features` { $\sqrt{p}$ , 0,3}; am besten war `max_depth=20`, `min_samples_leaf=1`, `max_features=0.3`.

**Code-Einstiegspunkte**: `awp2.experiment.tune()` und `run()`; Baseline mit Fehleranalyse in `notebooks/01_jd_baseline.ipynb`; ein vollständiger Durchlauf von den Rohdaten bis zur Testvorhersage (ca. 15 s) in `notebooks/03_jd_pipeline_rundgang.ipynb`.

### 4.3 Ergebnisse

**Tabelle 3**: Baseline auf dem Holdout (1.677 Zeilen). BAcc = Balanced Accuracy; „kombiniert“ zählt nur, wenn **Crop** und **Stage** beide stimmen.

| Modell        | Crop  |          | Stage |          | kombiniert   |          |            |
|---------------|-------|----------|-------|----------|--------------|----------|------------|
|               | BAcc  | Macro-F1 | BAcc  | Macro-F1 | BAcc         | Macro-F1 | Samples-F1 |
| Dummy         | 0,200 | 0,109    | 0,167 | 0,072    | 0,044        | 0,009    | 0,326      |
| Random Forest | 0,890 | 0,873    | 0,870 | 0,862    | <b>0,743</b> | 0,708    | 0,878      |




Abbildung 6: Zeilennormierte Confusion Matrices des Random Forest auf dem Holdout.

#### 4.4 Einordnung

- **Deutlich über Zufallsniveau:** Der Dummy liegt exakt beim Zufallsniveau (1/5 bzw. 1/6); der Random Forest erkennt Kultur und Stadium im Klassenmittel jeweils zu knapp 90 %, das vollständige Paar zu 74 %. Die Messlatte für alle weiteren Ansätze ist **BAcc kombiniert 0,743**.
- **Ehrliche Schätzung:** Der Holdout-Score liegt im Streubereich der Cross-Validation ( $0,750 \pm 0,019$ ); es gibt keine Anzeichen für Überanpassung an den Holdout. Unterschiede unter etwa 0,02 sind zwischen Modellen nicht belastbar.
- **Fehlermuster:** Bei der Kultur werden vor allem Mais und Soja verwechselt, beim Stadium benachbarte Stadien. Am schwächsten ist **Mature\_Senesc** (Recall 0,79), das auch mit **Emerge\_VEarly** verwechselt wird – beide Phasen zeigen wenig grüne Vegetation und viel Boden.
- **Ungültige Paare:** 0,3 % der Vorhersagen sind Crop–Stage-Kombinationen, die im Training nicht vorkommen. Der Random Forest kennt die Abhängigkeit zwischen den Zielgrößen nicht; ohne Korrektur ist er keine abgabefertige Vorhersage.
- **Starke Abhängigkeit vom Kontext:** Ein Vergleich der Eingaben per Cross-Validation ergab für Spektren allein 0,570, mit vier Vegetationsindizes 0,590 und mit **AEZ/Month** 0,750 (BAcc kombiniert). Ein großer Teil der Leistung stammt also aus den Kontextmerkmalen – ob sie beim späteren Einsatz verfügbar und erwünscht sind, ist daher eine zentrale offene Frage.

#### 4.5 Reproduzierbarkeit und Experiment-Tracking

Alle Zufallsprozesse (Split, Folds, Modelle) verwenden einen festen Seed. Jeder Aufruf von `tune()` und `run()` wird lokal in MLflow protokolliert: Parameter, Metriken, Confusion Matrices, das trainierte Modell inklusive Vorverarbeitung, ein Hash der verwendeten Daten und der Git-Stand (Commit, ungespeicherte Änderungen). Dadurch lassen sich Läufe nach Ansatz gruppieren und vergleichen, jedes Ergebnis ist auf Code und Daten zurückführbar, und gespeicherte Modelle können direkt für die Vorhersage auf den Testdaten geladen werden. Ergebnisse, die das Team kennen soll, werden mit ihrer Run-ID im Experiment-Log (`docs/modelle/experimente.md`) festgehalten.

## 5 Fazit, offene Punkte und nächste Schritte

### 5.1 Ergebnis von Meilenstein 1

- Domänenziel und Grenzen der Vorhersage sind beschrieben.
- Die EDA hat Datenqualität, Klassenungleichgewicht, Kontextabhängigkeit und Redundanz der Bänder herausgearbeitet und daraus Cleaning-Empfehlungen abgeleitet.
- Eine gemeinsame, reproduzierbare Pipeline setzt diese Empfehlungen um und stellt Split, Vorverarbeitung, Bewertung und Tracking für alle Ansätze bereit.
- Die Random-Forest-Baseline erreicht eine kombinierte Balanced Accuracy von 0,743 und ist die Referenz für Meilenstein 2.

### 5.2 Offene Punkte

- Bedeutung des geforderten „70/30 Clusterplot-Splits“ klären.
- Verfügbarkeit von Feld-, Bild- oder räumlichen IDs sowie die Bedeutung von `Month` und `AEZ` klären – die Baseline hängt stark von beiden ab.

### 5.3 Nächste Schritte

- Modelle mit und ohne `AEZ` und `Month` sowie begründete Glättungs- oder Merkmalsreduktionsvarianten (Bandauswahl, PCA) innerhalb derselben Cross-Validation vergleichen; neue Schritte als Optionen der Pipeline.
- Die Abhängigkeit zwischen `Crop` und `Stage` nutzen (hierarchisch oder kombiniertes Label), damit nur gültige Paare vorhergesagt werden.
- Fehleranalyse für Mais/Soja und benachbarte Stadien; Vorhersage im Abgabeformat für die Testdaten.

## 6 Quellen im Projekt

- Domänenbeschreibung: `../domaene/index.md`
- Data Understanding und EDA: `../daten/m1-data-understanding.md`
- Vollständige EDA-Dokumentation: `../daten/eda.md`
- Datenpipeline: `../daten/pipeline.md`, Begründungen: `../daten/pipeline-entscheidungen.md`
- Metriken und Validierung: `../domaene/ml-aufgabe.md`
- Baseline-Ergebnisse: `../modelle/ansaetze/baseline.md`, Experiment-Log: `../modelle/experimente.md`
- Notebooks: `notebooks/01_jd_baseline.ipynb`, `notebooks/03_jd_pipeline_rundgang.ipynb`
- Offene Fragen an die Betreuung: `offene-fragen.md`