Abschlussbericht
Kulturpflanzen- und Entwicklungsstadiumsklassifikation

Domänenprojekt 2
Team: AE-ROOT

Stand: 28. Oktober 2026

Inhaltsverzeichnis

1 Ziel und Domäne **3**

1.1 Aufgabe und Motivation 3

1.2 Hyperspektrale Messungen und Kulturentwicklung 3

1.3 Untersuchungsziele und Abgrenzung 3

2 Daten und explorative Analyse **4**

2.1 Datengrundlage und Zielgrößen 4

2.2 Zentrale Befunde und Konsequenzen 4

3 Methodik und Validierung **4**

3.1 Datenaufbereitung und Merkmalsbildung 4

3.2 Evaluationsprotokoll und Reproduzierbarkeit 5

4 Modellvergleich und Auswahl **6**

4.1 Baseline und untersuchte Strategien 6

4.2 Vergleich und finales Modell 6

5 Datenreduktion **8**

6 Ergebnisse und Interpretation **8**

6.1 Vorhersageleistung und Fehleranalyse 8

6.2 Fachliche Einordnung und Erklärbarkeit 8

7 Modellkarte **8**

7.1 Identität und vorgesehene Nutzung 8

7.2 Ein- und Ausgaben, Daten und Leistung 8

7.3 Annahmen, Grenzen und Risiken 8

8 Fazit und Ausblick **8**

A Ergänzende Ergebnisse und Reproduktion **8**

1 Ziel und Domäne

1.1 Aufgabe und Motivation

Ziel des Projekts ist die gemeinsame Vorhersage der Kulturart (`Crop`) und ihres Entwicklungsstadiums (`Stage`) aus hyperspektralen Satellitenmessungen. Die Aufgabe wird als Challenge bearbeitet, in der alle Teams dieselbe Klassifikationsaufgabe untersuchen. Neben der Vorhersageleistung verlangt die Aufgabenstellung einen begründeten Vergleich verschiedener Modellierungsstrategien und eine Untersuchung des Zielkonflikts zwischen Datenreduktion und Klassifikationsleistung [1].

Die Kulturart beschreibt, was auf einer Fläche wächst; das Entwicklungsstadium ordnet die Beobachtung in den saisonalen Verlauf ein. Solche Informationen können landwirtschaftliches Monitoring, Agrarstatistik und die Planung von Bewirtschaftungsmaßnahmen unterstützen. Fernerkundung ermöglicht dabei die wiederholte Beobachtung großer oder schwer zugänglicher Gebiete und kann Feldbegehungen ergänzen [2]. Das vorliegende Projekt untersucht jedoch die Klassifikationsleistung auf den bereitgestellten Daten. Ob daraus ein praktischer Nutzen etwa für Bewässerung, Düngung oder Ernteplanung entsteht, wird nicht nachgewiesen.

1.2 Hyperspektrale Messungen und Kulturentwicklung

Ein Spektrum beschreibt die Reflexion einer Oberfläche über verschiedene Wellenlängen. Hyperspektrale Sensoren erfassen viele schmale Spektralbänder und können dadurch feine Unterschiede im Reflexionsverhalten abbilden. Grundlage der Aufgabe sind Messungen des Sensors Hyperion an Bord des Satelliten Earth Observing-1 (EO-1). Hyperion erfasste 220 Bänder im Bereich von etwa 400 bis 2.500 nm bei einer nominellen räumlichen Auflösung von 30 m [3]. Davon zu unterscheiden sind die 198 bereitgestellten Bandspalten zwischen 427 und 2.395 nm. Ihre Reihenfolge beschreibt die Wellenlängenachse einer Beobachtung, keine Zeitreihe.

Bei grüner Vegetation absorbieren Blattpigmente vor allem blaues und rotes Licht. Der starke Anstieg zum nahen Infrarot wird als Red Edge bezeichnet; die hohe Reflexion im nahen Infrarot hängt wesentlich mit der inneren Blattstruktur zusammen. Im kurzwelligen Infrarot beeinflussen unter anderem der Wassergehalt und trockene Pflanzenbestandteile das Signal. Mit der Kulturentwicklung verändern sich außerdem Blattfläche, Bodenbedeckung und Pflanzenhöhe. Diese Zusammenhänge motivieren die Klassifikation anhand spektraler Signaturen, garantieren aber keine eindeutige Trennung: Bodenanteile, Aufnahmebedingungen und Unterschiede innerhalb einer Kultur können ebenfalls zum gemessenen Spektrum beitragen.

Unterschieden werden Mais, Sojabohne, Winterweizen, Baumwolle und Reis sowie sechs Stadienkategorien: `Emerge_VEarly`, `Early_Mid`, `Critical`, `Late`, `Mature_Senesc` und `Harvest`. Diese Labels werden als vorgegebene Kategorien behandelt, nicht als bestätigte Zuordnung zu standardisierten phänologischen Skalen. Zusätzlich stehen die agroökologische Zone (`AEZ`) und der Aufnahmemonat (`Month`) als Kontextmerkmale zur Verfügung. Agroökologische Zonen gruppieren Gebiete nach natürlichen Anbaubedingungen wie Klima, Böden und Vegetationsperiode [1].

1.3 Untersuchungsziele und Abgrenzung

Die Modellierung muss ungleiche Klassenhäufigkeiten, seltene Crop-Stage-Paare und mögliche spektrale Überlappungen berücksichtigen. Kulturart und Stadium sind dabei keine unabhängigen Zielgrößen: Stadien können sich je nach Kultur unterschiedlich im Spektrum ausdrücken. Nicht beobachtete Kombinationen belegen allerdings nicht, dass diese fachlich unmöglich sind. Vor diesem Hintergrund leiten drei Fragen die Untersuchung:

1. Welche Modellierungsstrategie sagt Kulturart und Entwicklungsstadium unter vergleichbaren Evaluationsbedingungen am zuverlässigsten vorher?
2. Welchen zusätzlichen Nutzen liefern AEZ, Aufnahmemonat und abgeleitete Merkmale gegenüber den Spektralbändern allein?
3. Wie weit lässt sich der Eingabeumfang reduzieren, und welcher Verlust an Klassifikationsleistung entsteht dabei?

Die primäre Bewertungsmetrik ist die Balanced Accuracy, die den Recall gleichgewichtet über die Klassen mittelt. Ergänzend werden Macro-F1 und Samples-F1 betrachtet. Kulturart und Stadium werden jeweils separat ausgewertet; die gemeinsame Vorhersage wird zusätzlich untersucht [1]. Die Ergebnisse gelten zunächst für die untersuchte Datenbasis. Eine Übertragbarkeit auf andere Regionen, Jahre oder Sensoren und die Eignung für einen operativen Einsatz sind damit nicht belegt.

2 Daten und explorative Analyse

2.1 Datengrundlage und Zielgrößen

2.2 Zentrale Befunde und Konsequenzen

3 Methodik und Validierung

Abbildung 1 fasst die Trennung von Modellauswahl und Holdout-Bewertung zusammen.

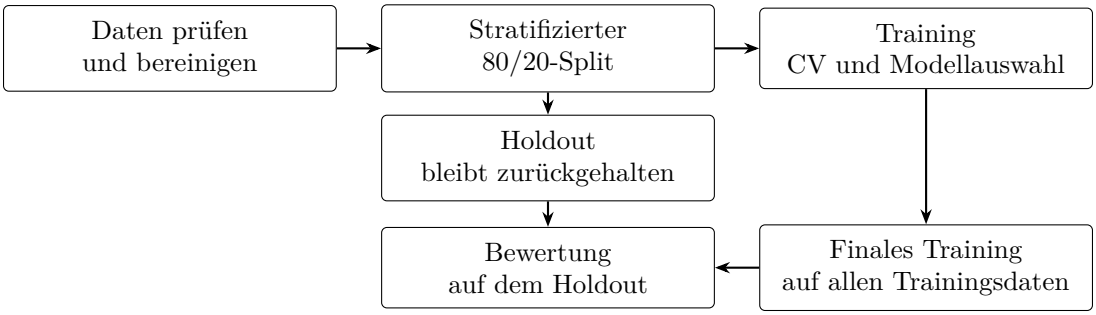


Abbildung 1: Kompakter Ablauf mit getrennter Trainings-CV und Holdout-Bewertung.

3.1 Datenaufbereitung und Merkmalsbildung

Alle Ansätze nutzen die gemeinsame Pipeline des Pakets `awp2`. Die Rohdaten werden auf Format, Wertebereiche und zulässige Labels geprüft. Nach dem Entfernen zweier exakter Duplikate verbleiben 5.589 Beobachtungen. Ausreißer werden nicht pauschal entfernt, da kein ausreichender Nachweis für Messfehler vorliegt. Die Kennung `id` und die Zielspalten sind keine Eingabemerkmale.

Von 198 Bandspalten bleiben nach Ausschluss vollständig leerer Bänder 131 nutzbar. Fehlende Werte werden entlang der Wellenlänge linear interpoliert, wenn die Stützbänder höchstens 15 nm auseinanderliegen; sonst wird der nächste Messwert verwendet. Bei vollständig fehlenden Spektren dienen Trainingsmediane als Ersatz. Die Skalierung ist modellabhängig: SVMs erhalten standardisierte Spektren, Baummodelle benötigen dies nicht.

Als Kontextmerkmale dienen `AEZ` und `Month`. Die Zone wird one-hot-kodiert, der Monat standardmäßig zyklisch durch Sinus und Kosinus dargestellt. Ihr Nutzen wird gegen Modelle ohne

Metadaten geprüft. Weitere Varianten umfassen Vegetationsindizes, Glättung, spektrale Normalisierung, PCA und Bandauswahl; ihre Ergebnisse folgen im Modellvergleich und bei der Datenreduktion. Sämtliche datenabhängigen Aufbereitungsschritte werden zusammen mit dem Modell nur auf den jeweiligen Trainingsdaten angepasst, nicht auf den zur Bewertung zurückgehaltenen Beobachtungen.

3.2 Evaluationsprotokoll und Reproduzierbarkeit

Aufteilung und Modellauswahl. Tabelle 1 zeigt das aktuelle Standardprotokoll. Die Aufteilung erfolgt mit Seed 42 stratifiziert nach `Crop|Stage`, damit auch seltene Zielpaare in beiden Teilen vertreten sind. Alle Ansätze laden dieselbe gespeicherte Zuordnung.

Tabelle 1: Gemeinsame Datenaufteilung nach der Duplikatbereinigung.

Bestandteil	Umfang bzw. Verwendung
Training	4.471 Beobachtungen (80 %)
Interner Holdout	1.118 Beobachtungen (20 %)
Trainings-CV	5 Folds innerhalb des Trainingsanteils

Hyperparameter und Merkmalsvarianten werden mit stratifizierter Cross-Validation (CV) ausschließlich im Trainingsanteil verglichen. Dabei wird jeweils auf vier Teilmengen trainiert und auf der fünften bewertet. Die Auswahl erfolgt anhand der mittleren kombinierten Balanced Accuracy. Anschließend wird die gewählte Pipeline auf dem gesamten Trainingsanteil angepasst und auf dem Holdout bewertet. Neuronale Modelle nutzen zusätzlich einen internen Trainingsanteil für frühes Stoppen. CV- und Holdout-Ergebnisse werden getrennt berichtet; ältere 70/30-Läufe sind nicht direkt mit dem aktuellen Protokoll vergleichbar.

Bewertungsmetriken. Die Hauptmetrik ist die **Balanced Accuracy (BAcc)**. Sie mittelt den Recall, also den Anteil richtig erkannter Beobachtungen einer Klasse, gleichgewichtet über die tatsächlichen Klassen. Dadurch erhalten seltene Klassen dasselbe Gewicht wie häufige. Ergänzend wird **Macro-F1** berichtet: der ungewichtete Mittelwert der klassenweisen F1-Werte, die Precision und Recall als harmonisches Mittel verbinden. Mit R_k als Recall und $F1_k$ als F1-Wert der Klasse k gilt jeweils für die K berücksichtigten Klassen:

$$\mathrm{BAcc} = \frac{1}{K}\sum_{k=1}^{K} R_k, \qquad F1_{\mathrm{macro}} = \frac{1}{K}\sum_{k=1}^{K} F1_k.$$

Beide Metriken werden für Kulturart, Stadium und das kombinierte Paar berechnet. Das Klassenungleichgewicht wird je nach Modell durch Klassen- oder Stichprobengewichte beziehungsweise gleiche Klassenprioren berücksichtigt. Confusion Matrices und der Anteil vorhergesagter Paare, die im Training nicht vorkamen, ergänzen die Fehleranalyse.

Grenzen und Nachvollziehbarkeit. Da mehrere Ansätze auf demselben Holdout bewertet wurden, ist dieser keine vollständig unabhängige Abschlussprüfung der Modellwahl. Zusätzliche Gruppen-CV nach AEZ, Monat oder deren Kombination zeigt deutlich geringere Leistungen bei unbekannten Kontextgruppen. Gute zufällige CV-Ergebnisse belegen daher keine Übertragbarkeit auf neue Regionen oder Zeitpunkte. Ohne Aufnahme- oder Feldkennungen lässt sich auch keine sichere Trennung tatsächlicher Aufnahmen oder Felder nachweisen.

Split-Artefakte, Seed und `uv.lock` stützen die Reproduktion. MLflow dient zur Laufdokumentation; Tracking-Ausfälle und nichtdeterministische Berechnungen bleiben Einschränkungen.

4 Modellvergleich und Auswahl

4.1 Baseline und untersuchte Strategien

Alle Modelle durchlaufen dasselbe Verfahren: Hyperparameter werden per fünffacher Kreuzvalidierung (CV) auf dem Trainingsanteil gesucht, der CV-Gewinner wird genau einmal auf dem Holdout bewertet. Das Klassenungleichgewicht wird über ausgeglichene Klassengewichte berücksichtigt. Als Untergrenze dient ein Dummy-Klassifikator, der immer die häufigste Klasse vorhersagt (BAcc kombiniert 0,044). Die eigentliche Baseline ist ein Random Forest, der Kulturart und Stadium gemeinsam vorhersagt (0,743); er liefert vereinzelt unmögliche Kombinationen (0,3 %).

Verglichen wurden vier Strategien, die sich darin unterscheiden, wie die Abhängigkeit zwischen Kulturart und Stadium genutzt wird:

- **Kombinierte Klasse:** Kulturart und Stadium bilden zusammen eine von 23 Klassen (`Crop|Stage`). Es entstehen nur beobachtete Paare; seltene Paare haben jedoch wenige Beispiele (Baumwolle/`Harvest`: 11).
- **Hierarchisch:** Zuerst wird die Kulturart bestimmt, dann entscheidet ein eigenes Modell je Kultur über das Stadium. Jeder Kulturfehler wird damit zum Stadiumsfehler.
- **Multi-Task:** Ein neuronales Netz mit gemeinsamen Schichten und zwei Ausgängen sagt beide Größen vorher.
- **Sequenzmodelle:** 1D-CNN, LSTM und GRU lesen das Spektrum als geordnete Folge entlang der Wellenlänge (keine Zeitreihe).

Unabhängig trainierte Einzelmodelle für Kulturart und Stadium wurden nicht untersucht. Als Klassifikatoren dienten RBF-SVM, Baum-Ensembles (Random Forest, Extra Trees, HistGradientBoosting), lineare Modelle, kNN und MLP. Die SVM passt zu stark korrelierten Bändern, weil sie glatte nichtlineare Grenzen lernt; sie braucht standardisierte Eingaben. Baumverfahren sind unempfindlich gegen die Skalierung und dienen als Gegenprobe. Die Suchräume blieben klein (meist unter 30 Kandidaten, für die zweistufige SVM 144). Eine spätere breite Suche prüfte zusätzlich 384 Kandidaten (acht Modellkonfigurationen, sechs Vorverarbeitungen, acht Einstellungen). Die vollständige Laufhistorie steht im Experimentprotokoll der Projektdokumentation und in MLflow.

4.2 Vergleich und finales Modell

Tabelle 2 stellt die wichtigsten Kandidaten gegenüber. Die Werte stammen aus zwei Splitprotokollen (70/30 bis zum 20. Oktober, danach 80/20) und sind nur innerhalb eines Blocks vergleichbar. CV-Werte sind Mittelwerte der fünf Trainingsfolds, Holdout-Werte einmalige Bewertungen.

Die kombinierte RBF-SVM liegt in beiden Protokollen vorn. Im 70/30-Split erreicht sie 0,866 und damit 0,12 mehr als die Baseline und 0,06 mehr als Extra Trees. Die hierarchische SVM bleibt in beiden Protokollen rund 0,02 darunter. Werden die Stadien mit der wahren Kultur angesteuert, steigt sie auf 0,94; der Engpass ist also die Kulturstufe, vor allem Winterweizen gegen Baumwolle und Mais gegen Soja. Weiches Routing, gemischte Klassifikatoren je Stufe und eine gewichtete Abstimmung brachten keinen CV-Gewinn von mindestens 0,005, der vorab als Mindestschwelle festgelegt war.

Das Multi-Task-Netz erreicht bei Kulturart und Stadium fast die SVM, aber nur 0,765 für das Paar. Sequenzmodelle bleiben deutlich zurück; ein GRU auf zehn Sentinel-2-Bändern ist mit 0,832 das beste davon. Bei rund 4.500 Trainingszeilen bringen die neuronalen Netze keinen Vorteil.

Zur zweiten Untersuchungsfrage: AEZ und Monat tragen am meisten. Ohne sie fällt die SVM

	CV	Holdout-BAcc			Macro-F1
Modell	komb.	Crop	Stage	komb.	komb.
Split 80/20					
Kombiniert, RBF-SVM mit AEZ × Monat	0,864	0,923	0,922	0,869	0,859
Kombiniert, RBF-SVM (breite Suche)	0,867	0,932	0,920	0,883	0,858
Hierarchisch, SVM → SVM	0,846	0,918	0,905	0,845	0,827
Kombiniert, GRU (10 Sentinel-2-Bänder)	0,794	0,908	0,890	0,832	0,773
Split 70/30					
Dummy (häufigste Klasse)	–	0,200	0,167	0,044	0,009
Baseline: Random Forest	0,750	0,890	0,870	0,743	0,708
Kombiniert, Random Forest	0,788	0,874	0,876	0,779	0,762
Kombiniert, Extra Trees	0,812	0,886	0,895	0,804	0,796
Kombiniert, RBF-SVM	0,847	0,931	0,906	0,866	0,830
Hierarchisch, SVM → SVM	0,839	0,920	0,902	0,844	0,820
Multi-Task-MLP (PCA-20)	0,728	0,920	0,902	0,765	0,726
Kombiniert, LSTM (Embeddings)	0,711	0,812	0,793	0,700	0,613
Kombiniert, 1D-CNN	0,611	0,819	0,712	0,626	0,559

Tabelle 2: Wichtigste Kandidaten. Alle Modelle außer der Random-Forest-Baseline sagen nur gültige Crop-Stage-Paare vorher. BAcc: Balanced Accuracy; komb.: gemeinsame Crop-Stage-Klasse.

von 0,845 auf 0,779 (70/30). Vegetationsindizes helfen der SVM nicht (0,842), verbessern aber Baumverfahren und logistische Regression in der CV um 0,015 bis 0,029. SNV, PCA-20 und andere Monatskodierungen brachten keinen Gewinn; nur AEZ-Monat-Indikatoren verbesserten die SVM geringfügig (CV +0,005, Holdout +0,003).

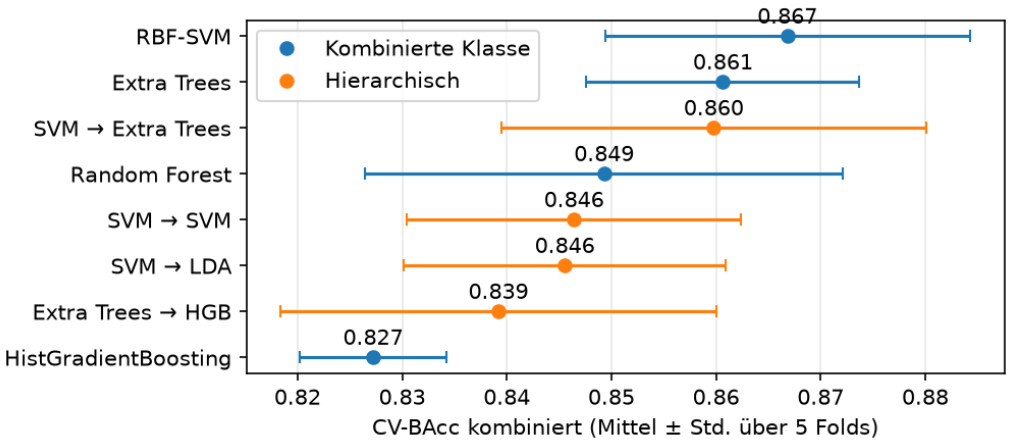


Abbildung 2: Beste CV-BAcc je Modellkonfiguration der breiten Suche (80/20, je 48 Kandidaten; Balken: Standardabweichung über die fünf Folds). Das Maximum über 48 Kandidaten macht alle Werte optimistisch.

Abbildung 2 prüft, ob die Rangfolge von der Hyperparameterwahl abhängt. Die SVM erreicht die höchste CV-BAcc (0,867), gefolgt von Extra Trees (0,861) und SVM → Extra Trees (0,860). Die Abstände liegen innerhalb der Fold-Streuung von 0,013 bis 0,020; eine verlässliche Reihenfolge der Spitzengruppe und ein Vorteil von kombiniert oder hierarchisch sind damit nicht belegt. Am schwächsten sind HistGradientBoosting (0,827) und Extra Trees → HGB (0,839); beide brauchen je Kandidat (fünf CV-Anpassungen) im Median rund 107 beziehungsweise 175 s statt 4 s für die SVM.

Modellwahl. Entscheidend war die CV-BAcc kombiniert; der Holdout dient nur als einmalige

Bestätigung. Zusätzlich zählen gültige Paare, geringer Rechenaufwand und Robustheit. Bei unbekannten Aufnahmen ist die hierarchische SVM etwas besser (0,42 statt 0,38), beide Modelle fallen jedoch stark ab (Kapitel 6). Gewählt wird daher die einfachere kombinierte RBF-SVM auf allen 131 Bändern mit AEZ-Monat-Indikatoren ($C = 300$, $\gamma = 0{,}003$): 0,869 BAcc kombiniert auf dem Holdout. Die breite Suche landet in derselben Modellfamilie und findet mit geglätteten Spektren, Albedo und Indizes eine Variante mit 0,883. Der Abstand liegt innerhalb der CV-Streuung und wurde auf einem mehrfach genutzten Holdout gemessen; er bestätigt die Modellfamilie, belegt aber keine gesicherte Verbesserung.

5 Datenreduktion

6 Ergebnisse und Interpretation

6.1 Vorhersageleistung und Fehleranalyse

6.2 Fachliche Einordnung und Erklärbarkeit

7 Modellkarte

7.1 Identität und vorgesehene Nutzung

7.2 Ein- und Ausgaben, Daten und Leistung

7.3 Annahmen, Grenzen und Risiken

8 Fazit und Ausblick

Literatur

[1] Domänenprojekt 2 (2026). *Beschreibung Domänenprojekt 2, Vorabversion 2026/27; Kickoff-Folien zur Aufgabenbeschreibung.* Bereitgestellte Projektunterlagen.

[2] Mulla, D. J. (2013). Twenty five years of remote sensing in precision agriculture: Key advances and remaining knowledge gaps. *Biosystems Engineering*, 114(4), 358–371. `https://doi.org/10.1016/j.biosystemseng.2012.08.009`.

[3] NASA (2025). *Earth Observing-1.* NASA Earth Observatory. `https://science.nasa.gov/earth/earth-observatory/earth-observing-1`.

A Ergänzende Ergebnisse und Reproduktion