Abschlussbericht
Kulturpflanzen- und Entwicklungsstadiumsklassifikation

Domänenprojekt 2
Team: AE-ROOT

Stand: 26. Oktober 2026

Inhaltsverzeichnis

1 Ziel und Domäne **3**

1.1 Aufgabe und Motivation 3

1.2 Hyperspektrale Messungen und Kulturentwicklung 3

1.3 Untersuchungsziele und Abgrenzung 3

2 Daten und explorative Analyse **4**

2.1 Datengrundlage und Zielgrößen 4

2.2 Zentrale Befunde und Konsequenzen 4

3 Methodik und Validierung **4**

3.1 Datenaufbereitung und Merkmalsbildung 4

3.2 Evaluationsprotokoll und Reproduzierbarkeit 6

4 Modellvergleich und Auswahl **9**

4.1 Baseline und untersuchte Strategien 9

4.2 Vergleich und finales Modell 9

5 Datenreduktion **9**

6 Ergebnisse und Interpretation **9**

6.1 Vorhersageleistung und Fehleranalyse 9

6.2 Fachliche Einordnung und Erklärbarkeit 9

7 Modellkarte **9**

7.1 Identität und vorgesehene Nutzung 9

7.2 Ein- und Ausgaben, Daten und Leistung 9

7.3 Annahmen, Grenzen und Risiken 9

8 Fazit und Ausblick **9**

A Ergänzende Ergebnisse und Reproduktion **10**

1 Ziel und Domäne

1.1 Aufgabe und Motivation

Ziel des Projekts ist die gemeinsame Vorhersage der Kulturart (`Crop`) und ihres Entwicklungsstadiums (`Stage`) aus hyperspektralen Satellitenmessungen. Die Aufgabe wird als Challenge bearbeitet, in der alle Teams dieselbe Klassifikationsaufgabe untersuchen. Neben der Vorhersageleistung verlangt die Aufgabenstellung einen begründeten Vergleich verschiedener Modellierungsstrategien und eine Untersuchung des Zielkonflikts zwischen Datenreduktion und Klassifikationsleistung [1].

Die Kulturart beschreibt, was auf einer Fläche wächst; das Entwicklungsstadium ordnet die Beobachtung in den saisonalen Verlauf ein. Solche Informationen können landwirtschaftliches Monitoring, Agrarstatistik und die Planung von Bewirtschaftungsmaßnahmen unterstützen. Fernerkundung ermöglicht dabei die wiederholte Beobachtung großer oder schwer zugänglicher Gebiete und kann Feldbegehungen ergänzen [2]. Das vorliegende Projekt untersucht jedoch die Klassifikationsleistung auf den bereitgestellten Daten. Ob daraus ein praktischer Nutzen etwa für Bewässerung, Düngung oder Ernteplanung entsteht, wird nicht nachgewiesen.

1.2 Hyperspektrale Messungen und Kulturentwicklung

Ein Spektrum beschreibt die Reflexion einer Oberfläche über verschiedene Wellenlängen. Hyperspektrale Sensoren erfassen viele schmale Spektralbänder und können dadurch feine Unterschiede im Reflexionsverhalten abbilden. Grundlage der Aufgabe sind Messungen des Sensors Hyperion an Bord des Satelliten Earth Observing-1 (EO-1). Hyperion erfasste 220 Bänder im Bereich von etwa 400 bis 2.500 nm bei einer nominellen räumlichen Auflösung von 30 m [3]. Davon zu unterscheiden sind die 198 bereitgestellten Bandspalten zwischen 427 und 2.395 nm. Ihre Reihenfolge beschreibt die Wellenlängenachse einer Beobachtung, keine Zeitreihe.

Bei grüner Vegetation absorbieren Blattpigmente vor allem blaues und rotes Licht. Der starke Anstieg zum nahen Infrarot wird als Red Edge bezeichnet; die hohe Reflexion im nahen Infrarot hängt wesentlich mit der inneren Blattstruktur zusammen. Im kurzwelligen Infrarot beeinflussen unter anderem der Wassergehalt und trockene Pflanzenbestandteile das Signal. Mit der Kulturentwicklung verändern sich außerdem Blattfläche, Bodenbedeckung und Pflanzenhöhe. Diese Zusammenhänge motivieren die Klassifikation anhand spektraler Signaturen, garantieren aber keine eindeutige Trennung: Bodenanteile, Aufnahmebedingungen und Unterschiede innerhalb einer Kultur können ebenfalls zum gemessenen Spektrum beitragen.

Unterschieden werden Mais, Sojabohne, Winterweizen, Baumwolle und Reis sowie sechs Stadienkategorien: `Emerge_VEarly`, `Early_Mid`, `Critical`, `Late`, `Mature_Senesc` und `Harvest`. Diese Labels werden als vorgegebene Kategorien behandelt, nicht als bestätigte Zuordnung zu standardisierten phänologischen Skalen. Zusätzlich stehen die agroökologische Zone (`AEZ`) und der Aufnahmemonat (`Month`) als Kontextmerkmale zur Verfügung. Agroökologische Zonen gruppieren Gebiete nach natürlichen Anbaubedingungen wie Klima, Böden und Vegetationsperiode [1].

1.3 Untersuchungsziele und Abgrenzung

Die Modellierung muss ungleiche Klassenhäufigkeiten, seltene Crop-Stage-Paare und mögliche spektrale Überlappungen berücksichtigen. Kulturart und Stadium sind dabei keine unabhängigen Zielgrößen: Stadien können sich je nach Kultur unterschiedlich im Spektrum ausdrücken. Nicht beobachtete Kombinationen belegen allerdings nicht, dass diese fachlich unmöglich sind. Vor diesem Hintergrund leiten drei Fragen die Untersuchung:

1. Welche Modellierungsstrategie sagt Kulturart und Entwicklungsstadium unter vergleichbaren Evaluationsbedingungen am zuverlässigsten vorher?
2. Welchen zusätzlichen Nutzen liefern AEZ, Aufnahmemonat und abgeleitete Merkmale gegenüber den Spektralbändern allein?
3. Wie weit lässt sich der Eingabeumfang reduzieren, und welcher Verlust an Klassifikationsleistung entsteht dabei?

Die primäre Bewertungsmetrik ist die Balanced Accuracy, die den Recall gleichgewichtet über die Klassen mittelt. Ergänzend werden Macro-F1 und Samples-F1 betrachtet. Kulturart und Stadium werden jeweils separat ausgewertet; die gemeinsame Vorhersage wird zusätzlich untersucht [1]. Die Ergebnisse gelten zunächst für die untersuchte Datenbasis. Eine Übertragbarkeit auf andere Regionen, Jahre oder Sensoren und die Eignung für einen operativen Einsatz sind damit nicht belegt.

2 Daten und explorative Analyse

2.1 Datengrundlage und Zielgrößen

2.2 Zentrale Befunde und Konsequenzen

3 Methodik und Validierung

Abbildung 1 zeigt den gemeinsamen Ablauf von der Bereinigung bis zur protokollierten Bewertung. Die Vorverarbeitung wird innerhalb jedes Trainingsfolds und anschließend beim Fit auf dem gesamten Trainingsanteil jeweils neu angepasst.

3.1 Datenaufbereitung und Merkmalsbildung

Alle Ansätze verwenden die gemeinsame Daten- und Vorverarbeitungspipeline des Pakets `awp2`. Beim Laden prüft ein Pandera-Schema Spalten, Datentypen, Wertebereiche und zulässige Labels. Vor der Aufteilung werden zwei exakt doppelte Beobachtungen entfernt, damit identische Messungen nicht zugleich im Training und in der Validierung vorkommen. Darüber hinaus werden keine als Ausreißer markierten Beobachtungen pauschal ausgeschlossen: Die dokumentierte Regelprüfung liefert keinen hinreichenden Nachweis für Messfehler. Die Kennung `id` dient nur der Zuordnung; sie und die Zielspalten `Crop` und `Stage` sind keine Eingabemerkmale.

Die modellabhängige Aufbereitung wird durch `PreprocessingConfig` festgelegt und gemeinsam mit dem Klassifikator in einer scikit-learn-Pipeline ausgeführt. Vollständig leere Bandspalten werden im jeweiligen Trainingsanteil erkannt und entfernt. In der bereinigten Datenbasis verbleiben so 131 der 198 Bandspalten. Einzelne Lücken werden innerhalb einer Beobachtung anhand der Wellenlänge linear interpoliert, sofern die beiden Stützbänder höchstens 15 nm auseinanderliegen. Bei größeren Abständen und am Spektralrand wird der nächste verfügbare Messwert verwendet. Das begrenzt die Interpolation über breite, nicht gemessene Spektralbereiche. Für vollständig fehlende Spektren stehen die im Trainingsanteil bestimmten Bandmediane als Rückfall zur Verfügung.

Die Skalierung richtet sich nach der Modellfamilie. Für abstandsbasierte Verfahren wie die RBF-SVM werden die Spektralmerkmale standardisiert; Baummodelle können ohne Skalierung arbeiten. Mittelwerte, Varianzen, Imputationswerte, Kategorien und gelernte Projektionen werden ausschließlich auf dem jeweiligen Trainingsfold bestimmt. Die zur Bewertung zurückgehaltenen Beobachtungen werden nur transformiert. Dadurch gelangen keine Informationen aus dem

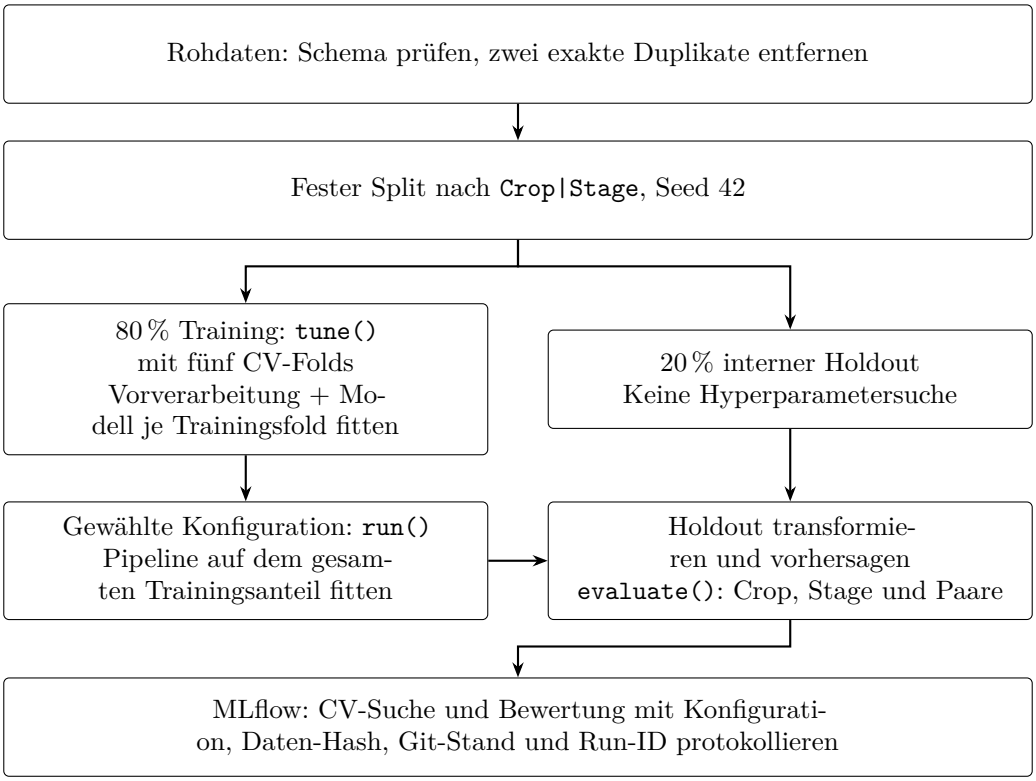


Abbildung 1: Standardprotokoll mit getrennten Datenrollen. Hyperparameter und Merkmalsvarianten werden innerhalb des Trainingsanteils verglichen; der interne Holdout dient der anschließenden Bewertung. Das Diagramm beschreibt den vorgesehenen Ablauf, nicht eine von allen Modellvergleichen unabhängige Abschlussprüfung.

Bewertungsfold in diese Anpassungsschritte.

Kontext und spektrale Varianten. Bei aktivierten Metadaten wird `AEZ` one-hot-kodiert. Der Aufnahmemonat wird standardmäßig durch Sinus und Kosinus mit einer Periode von zwölf Monaten dargestellt; die numerische Monatszahl bleibt eine Vergleichsvariante. Die aktuelle kombinierte SVM verwendet außerdem Indikatoren für die im Training beobachteten AEZ-Monat-Kombinationen. Sequenzmodelle können alternativ kategoriale Kontext-Embeddings nutzen. Dabei bleibt das Spektrum eine Folge entlang der Wellenlänge, nicht entlang der Zeit. Der Nutzen dieser Kontextmerkmale wird gegen spektrale Eingaben ohne Metadaten geprüft, weil sie auch regionale oder saisonale Stichprobenabhängigkeiten abbilden können.

Untersuchte spektrale Varianten umfassen Vegetationsindizes, Savitzky-Golay-Glättung, Standard Normal Variate (SNV), PCA und Bandauswahl. Indizes werden in einem eigenen Zweig aus den interpolierten, nicht SNV-transformierten Reflektanzen berechnet, damit Verhältnisse ihre ursprüngliche Bedeutung behalten. PCA und überwachte Bandauswahl werden je Trainingsfold gelernt. Eine Verringerung der PCA-Komponenten reduziert die Zahl der Modellmerkmale, nicht automatisch die Zahl benötigter Messbänder. Die gewählten Varianten und ihre Ergebnisse werden in den Kapiteln zum Modellvergleich und zur Datenreduktion getrennt ausgewiesen; nicht jede verfügbare Pipeline-Option gehört zum Referenzmodell.

3.2 Evaluationsprotokoll und Reproduzierbarkeit

Datenaufteilung und Modellauswahl. Seit dem 20.10.2026 verwendet das gemeinsame Standardprotokoll 80 % der bereinigten gelabelten Daten zum Training und 20 % als internen Holdout. Die Aufteilung wird mit dem festen Seed 42 nach dem kombinierten Label `Crop|Stage` stratifiziert. Innerhalb des Trainingsanteils werden fünf ebenfalls stratifizierte, zufällig gemischte CV-Folds verwendet. Stratifizierung nach Paaren berücksichtigt die seltenen Kombinationen besser als eine Aufteilung nur nach Kulturart oder Stadium. Die Zuordnung jeder Beobachtung und die Split-Konfiguration werden als gemeinsame Artefakte gespeichert und über `load_split()` und `load_folds()` geladen; eigene Aufteilungen einzelner Ansätze sind nicht Teil dieses Standardprotokolls. Tabelle 1 fasst das aktuelle Protokoll zusammen. Die Fallzahlen stammen aus `data/processed/split.csv`; der Holdout-Anteil ist in `data/processed/split_config.json` festgelegt.

Tabelle 1: Aktuelle Split- und CV-Konfiguration nach der Duplikatbereinigung.

Bestandteil	Umfang bzw. Einstellung
Bereinigte gelabelte Daten	5.589 Beobachtungen
Trainingsanteil	4.471 Beobachtungen (ca. 80 %)
Interner Holdout	1.118 Beobachtungen (ca. 20 %)
Trainings-CV	Fünf Folds, nur innerhalb der 4.471 Trainingszeilen
Bewertungsanteil je CV-Fold	894–895 Beobachtungen
Fit-Anteil je CV-Fold	3.576–3.577 Beobachtungen
Stratifizierung	Kombiniertes Label `Crop|Stage`
Zufallsstartwert	`SEED = 42`

`tune()` vergleicht Hyperparameterkandidaten per Grid Search ausschließlich innerhalb des Trainingsanteils. Standardmäßig wird die mittlere kombinierte Balanced Accuracy über die fünf Bewertungsfolds optimiert. Merkmalsvarianten werden ebenfalls anhand der Trainings-CV verglichen. Nach der Auswahl passt `run()` die gesamte Pipeline auf dem Trainingsanteil an und bewertet ihre Vorhersagen auf dem Holdout. CV-Mittelwerte und Fold-Streuung werden von den

Holdout-Kennzahlen getrennt berichtet; die Fold-Streuung ist kein Konfidenzintervall und belegt allein keine statistische Signifikanz eines Unterschieds.

Frühere Experimente beruhen auf einem 70/30-Split. Deren Kennzahlen sind nicht unmittelbar mit dem aktuellen 80/20-Protokoll vergleichbar. Für direkte Vergleiche müssen Split, Fold-Zuordnung und Bewertungsmetrik übereinstimmen; unterschiedliche Eingaben und Suchbudgets sind offenzulegen. Der vorgesehene Ablauf sieht eine Holdout-Bewertung je ausgewähltem Ansatz vor. Das Experimentprotokoll enthält jedoch mehrere Modell- und Merkmalsvergleiche auf demselben Holdout. Dieser ist daher keine vollständig unabhängige Abschlussprüfung der gesamten Modellwahl; eine Auswahl anhand bereits bekannter Validierungswerte kann die Leistungsschätzung optimistisch machen. Die ungelabelten Abgabedaten sind davon getrennt und erlauben ohne externe Rückmeldung keine eigene Berechnung der Vorhersagegüte.

Metriken und Klassenungleichgewicht. Die gemeinsame Funktion `evaluate()` berechnet Balanced Accuracy und Macro-F1 jeweils für Kulturart, Stadium und das kombinierte Paar. Die Balanced Accuracy mittelt den Recall gleichgewichtet über die tatsächlichen Klassen und verhindert so, dass häufige Klassen die Hauptmetrik dominieren. Macro-F1 ergänzt diese Sicht um klassenweise Precision und Recall. Samples-F1 bewertet dagegen den Anteil korrekt vorhergesagter Labels je Beobachtung. Bei genau einer Kultur- und einer Stadiumsvorhersage gilt:

$$F1_{\text{samples}} = \frac{1}{2n} \sum_{i=1}^{n} \left(\mathbf{1}(\widehat{c}_i = c_i) + \mathbf{1}(\widehat{s}_i = s_i) \right).$$

Hier bezeichnet n die Zahl der Beobachtungen und $\mathbf{1}$ die Indikatorfunktion; c_i und s_i sind die wahren Kultur- und Stadienlabels, die mit Dach bezeichneten Werte ihre Vorhersagen. Eine Beobachtung trägt somit 1, 0,5 oder 0 bei. Samples-F1 ist keine klassenbalancierte Metrik und kein Anteil ausschließlich vollständig korrekter Paare.

Dem Klassenungleichgewicht begegnen die Modelle je nach Verfahren mit ausgeglichenen Klassen- oder Stichprobengewichten beziehungsweise angepassten Klassenprioren. Bei kombinierten Klassifikatoren beziehen sich die Gewichte auf Crop-Stage-Paare, bei hierarchischen Verfahren auf die jeweilige Klassifikationsstufe. Die konkrete Einstellung gehört zur Modellkonfiguration. Zusätzlich wird der Anteil vorhergesagter Paare außerhalb der im Training beobachteten Kombinationen ausgewiesen. Kombinierte Klassen und entsprechende Paarbeschränkungen vermeiden solche Ausgaben konstruktiv; die Bewertungsfunktion selbst korrigiert sie nicht. Confusion Matrices sowie Precision, Recall und Fallzahlen je Klasse ergänzen die aggregierten Kennzahlen in der Fehleranalyse.

Abhängigkeiten und Reproduktion. Ein zufälliger Split belegt keine Übertragbarkeit auf neue Regionen oder Aufnahmezeitpunkte. Ergänzende Analysen verwenden deshalb Gruppen-CV nach AEZ, Monat oder deren Kombination, ausschließlich auf dem Trainingsanteil. AEZ-Monat-Gruppen sind dabei Kontextgruppen und ohne eindeutige Aufnahme- oder Feldkennung kein Nachweis einer Trennung tatsächlicher Satellitenaufnahmen oder Felder. Die Ergebnisse dieses abweichenden Protokolls werden separat von der Standard-CV eingeordnet. Abbildung 2 zeigt am kombinierten Ansatz, wie stark sich die Bewertung mit der Fold-Art ändert. Bei allen Bändern beträgt die kombinierte CV-Balanced-Accuracy etwa 0,859 bei zufälligen Folds, gegenüber 0,378 bei getrennten AEZ-Monat-Gruppen, 0,421 bei getrennten Monaten und 0,284 bei getrennten AEZ. Diese Unterschiede begrenzen die Interpretation der Standard-CV: Gute Vorhersagen innerhalb der vorhandenen Datenverteilung belegen keine vergleichbare Leistung für nicht im Training vertretene Kontextgruppen. Die Grafik stammt aus `notebooks/34_jd_gruppen_cv.ipynb`; die zugehörigen Läufe stehen im MLflow-Experiment `split-leakage`.

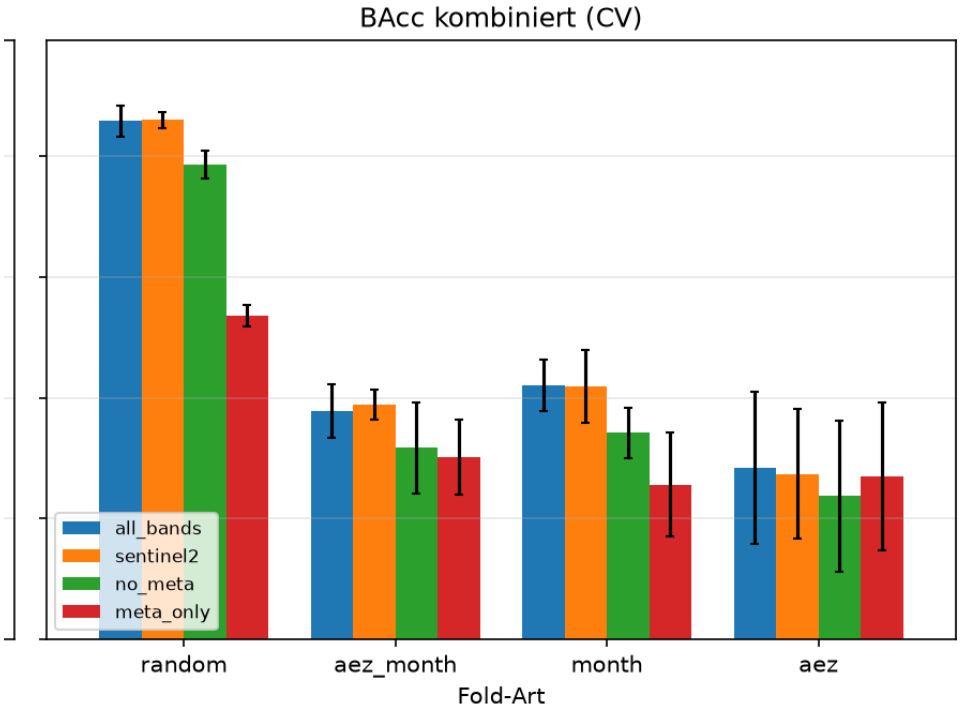


Abbildung 2: Zufällige und gruppierte Trainings-CV im 80/20-Protokoll für den kombinierten Ansatz (Ausschnitt: kombinierte Balanced Accuracy). `random` bezeichnet zufällige stratifizierte Folds; die übrigen Fold-Arten trennen AEZ-Monat-Gruppen, Monate bzw. AEZ. Verglichen werden alle Bänder, simulierte Sentinel-2-Bänder, Spektren ohne Metadaten und ausschließlich Metadaten. Die Fehlerbalken zeigen die Standardabweichung über die Folds, keine Konfidenzintervalle.

Die Reproduktion beginnt mit `uv sync -locked` und der Bereitstellung der Rohdaten. `make data` erzeugt die bereinigten Daten sowie die Split- und Fold-Artefakte. Die Python-Umgebung ist durch `pyproject.toml` und `uv.lock` festgelegt, Seed und Standardanteile durch `src/awp2/config.py`. Notebooks rufen wiederverwendbare Funktionen des Pakets auf; Vorverarbeitung und Bewertungslogik stehen in `src/awp2/preprocessing.py`, `src/awp2/experiment.py` und `src/awp2/evaluation.py`. Bei aktivierter Nachverfolgung speichert MLflow Tuning-Kandidaten, Konfigurationen, Datenfingerabdrücke, Git-Stand, Metriken und Modellartefakte. Das gemeinsame Experimentprotokoll in `docs/modelle/experimente.md` verweist auf die Run-IDs; dokumentierte Tracking-Ausfälle sind als Lücken der Nachvollziehbarkeit zu berücksichtigen. Ein fester Seed allein garantiert zudem keine bit-identischen Resultate bei unterschiedlichen Laufzeitumgebungen oder nichtdeterministischen Mehrthread-Verfahren. Für das finale Modell sind deshalb der ausgewertete Code-Stand, seine Konfiguration und die konkrete Run-ID gemeinsam anzugeben.

4 Modellvergleich und Auswahl

4.1 Baseline und untersuchte Strategien

4.2 Vergleich und finales Modell

5 Datenreduktion

6 Ergebnisse und Interpretation

6.1 Vorhersageleistung und Fehleranalyse

6.2 Fachliche Einordnung und Erklärbarkeit

7 Modellkarte

7.1 Identität und vorgesehene Nutzung

7.2 Ein- und Ausgaben, Daten und Leistung

7.3 Annahmen, Grenzen und Risiken

8 Fazit und Ausblick

Literatur

[1] Domänenprojekt 2 (2026). *Beschreibung Domänenprojekt 2, Vorabversion 2026/27; Kickoff-Folien zur Aufgabenbeschreibung.* Bereitgestellte Projektunterlagen.

[2] Mulla, D. J. (2013). Twenty five years of remote sensing in precision agriculture: Key advances and remaining knowledge gaps. *Biosystems Engineering*, 114(4), 358–371. `https://doi.org/10.1016/j.biosystemseng.2012.08.009`.

[3] NASA (2025). *Earth Observing-1.* NASA Earth Observatory. `https://science.nasa.gov/earth/earth-observatory/earth-observing-1`.

A Ergänzende Ergebnisse und Reproduktion