Abschlussbericht
Kulturpflanzen- und Entwicklungsstadiumsklassifikation

Jan-David Wiederstein (wija1025)
Achim Duong (duac1011)
Pascal Heinzelmann (hepa1037)

Domänenprojekt 2
Team: AE-ROOT

Stand: 31. Oktober 2026

Inhaltsverzeichnis

1 Ziel und Domäne **1**

2 Daten und explorative Analyse **2**

3 Methodik und Validierung **4**

4 Modellvergleich und Auswahl **6**

5 Datenreduktion **8**

6 Ergebnisse und Interpretation **12**

7 Modellkarte **17**

8 Fazit und Ausblick **18**

1 Ziel und Domäne

1.1 Aufgabe und Motivation

Ziel des Projekts ist die gemeinsame Vorhersage der Kulturart (`Crop`) und ihres Entwicklungsstadiums (`Stage`) aus hyperspektralen Satellitenmessungen. Die Aufgabe wird als Challenge bearbeitet, in der alle Teams dieselbe Klassifikationsaufgabe untersuchen. Neben der Vorhersageleistung verlangt die Aufgabenstellung einen begründeten Vergleich verschiedener Modellierungsstrategien und eine Untersuchung des Zielkonflikts zwischen Datenreduktion und Klassifikationsleistung.

Die Kulturart beschreibt, was auf einer Fläche wächst; das Entwicklungsstadium ordnet die Beobachtung in den saisonalen Verlauf ein. Solche Informationen können landwirtschaftliches Monitoring, Agrarstatistik und die Planung von Bewirtschaftungsmaßnahmen unterstützen. Fernerkundung ermöglicht dabei die wiederholte Beobachtung großer oder schwer zugänglicher Gebiete und kann Feldbegehungen ergänzen [1]. Das vorliegende Projekt untersucht jedoch die Klassifikationsleistung auf den bereitgestellten Daten. Ob daraus ein praktischer Nutzen etwa für Bewässerung, Düngung oder Ernteplanung entsteht, wird nicht nachgewiesen.

1.2 Hyperspektrale Messungen und Kulturentwicklung

Ein Spektrum beschreibt die Reflexion einer Oberfläche über verschiedene Wellenlängen. Hyperspektrale Sensoren erfassen viele schmale Spektralbänder und können dadurch feine Unterschiede im Reflexionsverhalten abbilden. Grundlage der Aufgabe sind Messungen des Sensors Hyperion an Bord des Satelliten Earth Observing-1 (EO-1). Hyperion erfasste 220 Bänder im Bereich von etwa 400 bis 2.500 nm bei einer nominellen räumlichen Auflösung von 30 m [4]. Davon zu unterscheiden sind die 198 bereitgestellten Bandspalten zwischen 427 und 2.395 nm. Ihre Reihenfolge beschreibt die Wellenlängenachse einer Beobachtung, keine Zeitreihe.

Bei grüner Vegetation absorbieren Blattpigmente vor allem blaues und rotes Licht. Der starke Anstieg zum nahen Infrarot wird als Red Edge bezeichnet; die hohe Reflexion im nahen Infrarot hängt wesentlich mit der inneren Blattstruktur zusammen. Im kurzwelligen Infrarot beeinflussen unter anderem der Wassergehalt und trockene Pflanzenbestandteile das Signal. Mit der Kulturentwicklung verändern sich außerdem Blattfläche, Bodenbedeckung und Pflanzenhöhe. Diese Zusammenhänge motivieren die Klassifikation anhand spektraler Signaturen, garantieren aber keine eindeutige Trennung: Bodenanteile, Aufnahmebedingungen und Unterschiede innerhalb einer Kultur können ebenfalls zum gemessenen Spektrum beitragen.

Unterschieden werden Mais, Sojabohne, Winterweizen, Baumwolle und Reis sowie sechs Stadienkategorien: `Emerge_VEarly`, `Early_Mid`, `Critical`, `Late`, `Mature_Senesc` und `Harvest`. Diese Labels werden als vorgegebene Kategorien behandelt, nicht als bestätigte Zuordnung zu standardisierten phänologischen Skalen. Zusätzlich stehen die agroökologische Zone (`AEZ`) und der Aufnahmemonat (`Month`) als Kontextmerkmale zur Verfügung. Agroökologische Zonen gruppieren Gebiete nach natürlichen Anbaubedingungen wie Klima, Böden und Vegetationsperiode.

1.3 Untersuchungsziele und Abgrenzung

Die Modellierung muss ungleiche Klassenhäufigkeiten, seltene Crop-Stage-Paare und mögliche spektrale Überlappungen berücksichtigen. Kulturart und Stadium sind dabei keine unabhängigen Zielgrößen: Stadien können sich je nach Kultur unterschiedlich im Spektrum ausdrücken. Vor diesem Hintergrund leiten drei Fragen die Untersuchung:

1. Welche Modellierungsstrategie sagt Kulturart und Entwicklungsstadium unter vergleichbaren

Evaluationsbedingungen am zuverlässigsten vorher?
2. Welchen zusätzlichen Nutzen liefern AEZ, Aufnahmemonat und abgeleitete Merkmale gegenüber den Spektralbändern allein?
3. Wie weit lässt sich der Eingabeumfang reduzieren, und welcher Verlust an Klassifikationsleistung entsteht dabei?

Bewertet wird mit Balanced Accuracy und Macro-F1, jeweils für Kulturart, Stadium und das Paar, sowie mit Samples-F1 (Abschnitt 3.2). Die Ergebnisse gelten zunächst für die untersuchte Datenbasis. Eine Übertragbarkeit auf andere Regionen, Jahre oder Sensoren und die Eignung für einen operativen Einsatz sind damit nicht belegt.

2 Daten und explorative Analyse

2.1 Datengrundlage und Zielgrößen

Die Daten entsprechen in Aufbau und Labels der hyperspektralen Bibliothek GHISACONUS für die USA [6, 5]: fünf Kulturarten, sechs Entwicklungsstadien und sieben agroökologische Zonen aus Hyperion-Aufnahmen der Jahre 2008 bis 2015. Je Feld wurde dort ein Pixel abseits des Feldrandes ausgewählt, mit einem Atmosphärenmodell (SMARTS) in Bodenreflektanz umgerechnet und über drei benachbarte Bänder geglättet [5]. Welche Aufnahmen die Challenge daraus ausgewählt hat und wie die Codes von `AEZ` genau definiert sind, ist nicht dokumentiert.

Eine Zeile beschreibt ein Spektrum: 198 Reflektanzwerte in Prozent zwischen 427 und 2.395 nm sowie die Kontextmerkmale `AEZ` (Zonen 2 und 5–10) und `Month` (Mai bis Oktober). Die gelabelte Datei `train.csv` umfasst 5.591 Beobachtungen und dient der gesamten Entwicklung; die ungelabelte Datei `test.csv` mit 1.397 Beobachtungen wird nur für die finale Vorhersage verwendet, ihre Labelverteilung ist unbekannt. Tabelle 1 zeigt die Zielgrößen. Von 30 denkbaren Kombinationen aus Kultur und Stadium kommen 23 vor. Fehlende Paare sind ein Befund der Stichprobe, keine fachliche Unmöglichkeit; Vorhersagen werden dennoch auf die beobachteten Paare beschränkt.

Tabelle 1: Beobachtungen je Kultur und Stadium in `train.csv` (vor der Duplikatbereinigung).

Kultur	Emerge_VEarly	Early_Mid	Critical	Late	Mature_Senesc	Harvest	Summe
corn	152	212	675	557	399	102	2.097
soybean	106	465	652	233	146	67	1.669
winter_wheat	608	–	56	30	379	–	1.073
cotton	172	253	158	–	65	11	659
rice	–	52	–	41	–	–	93
Summe	1.038	982	1.541	861	989	180	5.591

2.2 Zentrale Befunde und Konsequenzen

Starkes Klassenungleichgewicht. Mais und Sojabohne stellen zwei Drittel der Daten, Reis nur 93 Beobachtungen. Das seltenste Paar `cotton|Harvest` hat 11 Beobachtungen. Deshalb wird nach `Crop|Stage` stratifiziert, Balanced Accuracy und Macro-F1 ersetzen die einfache Accuracy, und die Modelle gewichten Klassen ausgeglichen (Abschnitt 3.2). Werte für seltene Paare bleiben unsicher.

Datenqualität. In beiden Dateien sind dieselben 67 Bandspalten vollständig leer, vor allem in den Wasserabsorptionsbereichen um 950, 1.130, 1.400 und 1.900 nm und an den Rändern.

Es bleiben 131 Bänder in fünf zusammenhängenden Abschnitten (437–923, 983–1.094, 1.175–1.316, 1.518–1.760 und 2.063–2.345 nm). Einzelne Werte fehlen nur in 44 Trainings- und 11 Testzeilen, ohne Häufung in einer Gruppe. Zwei Paare von Trainingszeilen sind exakt identisch; zwischen Training und Test gibt es keine identischen Eingaben. Daraus folgen das Entfernen leerer Bänder und der Duplikate sowie die Interpolation entlang der Wellenlänge (Abschnitt 3.1). Das Reflexionsniveau ist im Blauen mit einem Median von etwa 16 % deutlich höher als für Vegetation an der Oberfläche üblich; die Werte enthalten offenbar noch einen Atmosphären- oder Kalibrieranteil. Eine Regelprüfung mit relativen Schwellen markiert 5,5 % der Zeilen als spektrale Ausreißer ihrer Klasse. Sie bündeln sich in einzelnen kleinen AEZ-Monat-Zellen mit hellen, bodenartigen Spektren und sind damit eher echte Beobachtungen als Messfehler; sie werden nicht entfernt.

Spektren unterscheiden sich, überlappen aber. Abbildung 1 zeigt die erwartete Vegetationsform mit Chlorophyllabsorption um 670 nm, steilem Anstieg an der Red Edge und hohem NIR-Plateau. Die Kulturen unterscheiden sich vor allem im NIR (Reis am hellsten, Baumwolle und Winterweizen am dunkelsten) und im SWIR, wo Baumwolle und Winterweizen mit mehr Boden- oder Trockenmasseanteil heller sind. Innerhalb einer Kultur verschieben sich die Stadien besonders im NIR und SWIR. Die Streubereiche überlappen jedoch stark, sodass kein einzelnes Band und keine einzelne Kurve eine Klasse festlegt. Das Helligkeitsniveau selbst trägt Information; eine Normalisierung jedes Spektrums (SNV) verschlechtert die Klassifikation entsprechend.

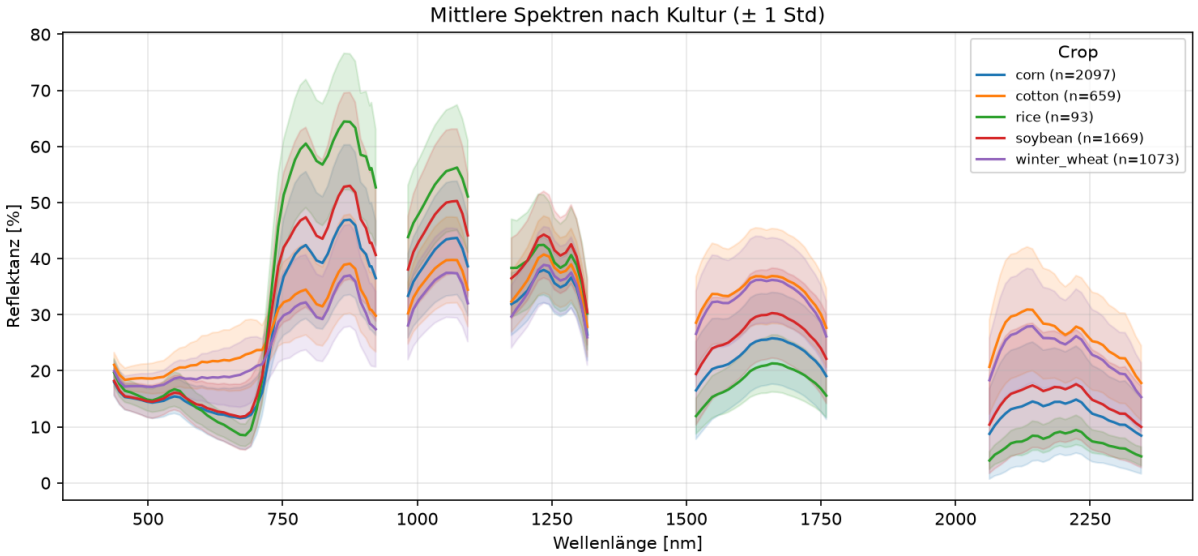


Abbildung 1: Mittlere Spektren je Kultur (± eine Standardabweichung). Lücken markieren vollständig leere Bandbereiche.

Benachbarte Bänder sind redundant. Benachbarte nutzbare Bänder korrelieren im Median mit 0,999. Univariat liegen die größten Unterschiede zwischen Kulturen zwischen 600 und 700 nm, zwischen Stadien am Übergang zum NIR (760–875 nm) und im SWIR. Das begründet die Untersuchung von Dimensionsreduktion und Bandauswahl (Abschnitt 5); jede solche Auswahl wird nur im Trainingsfold gelernt.

Kontext strukturiert die Labels stark. Die Zonen enthalten sehr unterschiedliche Kulturen: In AEZ 2 kommt nur Baumwolle, in AEZ 8 nur Mais und Reis nur in AEZ 7 vor. Innerhalb einer Kultur hängt das Stadium eng am Monat (Abbildung 2): Mais im August ist ausschließlich `Critical`, Winterweizen läuft im September und Oktober auf. Die 1.397 Testzeilen liegen

in denselben 32 Kombinationen aus Zone und Monat wie das Training. `AEZ` und `Month` sind deshalb starke, zulässige Merkmale, können aber Aufnahme- und Regionseffekte statt spektraler Unterschiede abbilden. Wie stark die Leistung für unbekannte Zonen oder Monate sinkt, prüft die Gruppen-CV (Abschnitt 6).

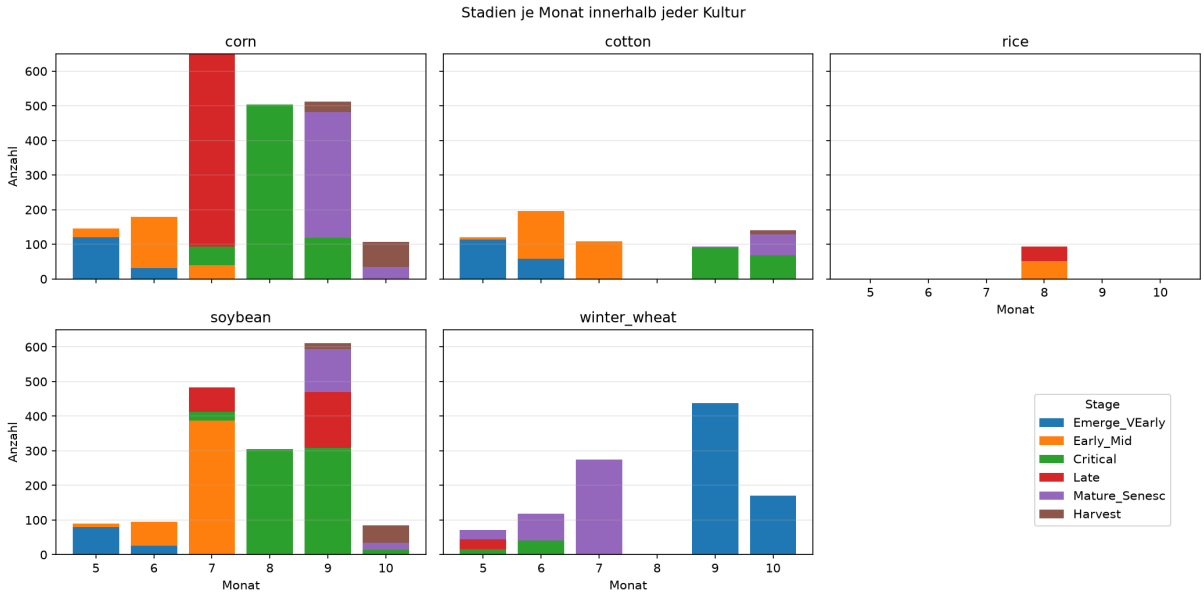


Abbildung 2: Beobachtungen je Monat und Stadium innerhalb jeder Kultur.

3 Methodik und Validierung

Abbildung 3 fasst die Trennung von Modellauswahl und Holdout-Bewertung zusammen.

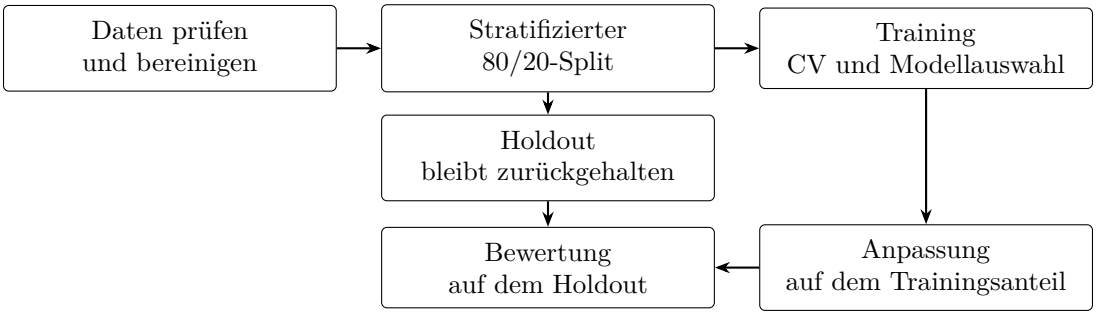


Abbildung 3: Kompakter Ablauf mit getrennter Trainings-CV und Holdout-Bewertung.

3.1 Datenaufbereitung und Merkmalsbildung

Alle Ansätze nutzen die gemeinsame Pipeline des Pakets `awp2`. Die Rohdaten werden auf Format, Wertebereiche und zulässige Labels geprüft. Nach dem Entfernen zweier exakter Duplikate verbleiben 5.589 Beobachtungen; Ausreißer bleiben erhalten (Abschnitt 2). Die Kennung `id` und die Zielspalten sind keine Eingabemerkmale.

In den 131 nutzbaren Bändern werden fehlende Werte entlang der Wellenlänge linear interpoliert, wenn die Stützbänder höchstens 15 nm auseinanderliegen; sonst wird der nächste Messwert verwendet. Bei vollständig fehlenden Spektren dienen Trainingsmediane als Ersatz. Die Skalierung ist modellabhängig: SVMs erhalten standardisierte Spektren, Baummodelle benötigen dies nicht.

Als Kontextmerkmale dienen `AEZ` und `Month`. Die Zone wird one-hot-kodiert, der Monat standardmäßig zyklisch durch Sinus und Kosinus dargestellt. Ihr Nutzen wird gegen Modelle ohne Metadaten geprüft. Weitere Varianten umfassen Vegetationsindizes, Glättung, spektrale Normalisierung, PCA und Bandauswahl; ihre Ergebnisse folgen im Modellvergleich und bei der Datenreduktion. Sämtliche datenabhängigen Aufbereitungsschritte werden zusammen mit dem Modell nur auf den jeweiligen Trainingsdaten angepasst, nicht auf den zur Bewertung zurückgehaltenen Beobachtungen.

3.2 Evaluationsprotokoll und Reproduzierbarkeit

Aufteilung und Modellauswahl. Tabelle 2 zeigt das Standardprotokoll. Die Aufteilung erfolgt mit Seed 42 stratifiziert nach `Crop|Stage`, damit auch seltene Zielpaare in beiden Teilen vertreten sind. Alle Ansätze laden dieselbe gespeicherte Zuordnung.

Tabelle 2: Gemeinsame Datenaufteilung nach der Duplikatbereinigung.

Bestandteil	Umfang bzw. Verwendung
Training	4.471 Beobachtungen (80 %)
Interner Holdout	1.118 Beobachtungen (20 %)
Trainings-CV	5 Folds innerhalb des Trainingsanteils

Hyperparameter und Merkmalsvarianten werden mit stratifizierter Cross-Validation (CV) ausschließlich im Trainingsanteil verglichen. Dabei wird jeweils auf vier Teilmengen trainiert und auf der fünften bewertet. Die Auswahl erfolgt anhand der mittleren kombinierten Balanced Accuracy. Anschließend wird die gewählte Pipeline auf dem gesamten Trainingsanteil angepasst und auf dem Holdout bewertet. Neuronale Modelle nutzen zusätzlich einen internen Trainingsanteil für frühes Stoppen. CV- und Holdout-Ergebnisse werden getrennt berichtet; ältere 70/30-Läufe sind nicht direkt mit dem aktuellen Protokoll vergleichbar.

Bewertungsmetriken. Die Hauptmetrik ist die **Balanced Accuracy (BAcc)**. Sie mittelt den Recall, also den Anteil richtig erkannter Beobachtungen einer Klasse, gleichgewichtet über die tatsächlichen Klassen. Dadurch erhalten seltene Klassen dasselbe Gewicht wie häufige. Ergänzend wird **Macro-F1** berichtet: der ungewichtete Mittelwert der klassenweisen F1-Werte, die Precision und Recall als harmonisches Mittel verbinden. Mit R_k als Recall und $F1_k$ als F1-Wert der Klasse k gilt jeweils für die K berücksichtigten Klassen:

$$\mathrm{BAcc} = \frac{1}{K}\sum_{k=1}^{K} R_k, \qquad F1_{\mathrm{macro}} = \frac{1}{K}\sum_{k=1}^{K} F1_k.$$

Beide Metriken werden für Kulturart, Stadium und das kombinierte Paar berechnet. **Samples-F1** behandelt Kulturart und Stadium je Beobachtung als zwei Labels und mittelt den F1-Wert über die Beobachtungen; ein halb richtiges Paar zählt damit teilweise. Das Klassenungleichgewicht wird je nach Modell durch Klassen- oder Stichprobengewichte beziehungsweise gleiche Klassenprioren berücksichtigt. Confusion Matrices und der Anteil vorhergesagter Paare, die im Training nicht vorkamen, ergänzen die Fehleranalyse.

Grenzen und Nachvollziehbarkeit. Da mehrere Ansätze auf demselben Holdout bewertet wurden, ist dieser keine vollständig unabhängige Abschlussprüfung der Modellwahl. Zusätzliche Gruppen-CV nach AEZ, Monat oder deren Kombination zeigt deutlich geringere Leistungen bei

unbekannten Kontextgruppen (Abschnitt 6). Gute zufällige CV-Ergebnisse belegen daher keine Übertragbarkeit auf neue Regionen oder Zeitpunkte. Ohne Aufnahme- oder Feldkennungen lässt sich auch keine sichere Trennung tatsächlicher Aufnahmen oder Felder nachweisen.

Split-Artefakte, Seed und `uv.lock` stützen die Reproduktion. MLflow dient zur Laufdokumentation; Tracking-Ausfälle und nichtdeterministische Berechnungen bleiben Einschränkungen.

4 Modellvergleich und Auswahl

4.1 Baseline und untersuchte Strategien

Als Untergrenze dient ein Dummy-Klassifikator, der immer die häufigste Klasse vorhersagt (BAcc kombiniert 0,044). Die eigentliche Baseline ist ein Random Forest, der Kulturart und Stadium gemeinsam vorhersagt (0,743); er liefert vereinzelt nicht beobachtete Kombinationen (0,3 %).

Verglichen wurden vier Strategien, die sich darin unterscheiden, wie die Abhängigkeit zwischen Kulturart und Stadium genutzt wird:

- **Kombinierte Klasse:** Kulturart und Stadium bilden zusammen eine von 23 Klassen (`Crop|Stage`). Es entstehen nur beobachtete Paare; seltene Paare haben jedoch wenige Beispiele.
- **Hierarchisch:** Zuerst wird die Kulturart bestimmt, dann entscheidet ein eigenes Modell je Kultur über das Stadium. Jeder Kulturfehler wird damit zum Stadiumsfehler.
- **Multi-Task:** Ein neuronales Netz mit gemeinsamen Schichten und zwei Ausgängen sagt beide Größen vorher.
- **Sequenzmodelle:** 1D-CNN, LSTM und GRU lesen das Spektrum als geordnete Folge entlang der Wellenlänge (keine Zeitreihe).

Unabhängig trainierte Einzelmodelle für Kulturart und Stadium wurden nicht gezielt untersucht. Als Klassifikatoren dienten RBF-SVM, Baum-Ensembles (Random Forest, Extra Trees, HistGradientBoosting), lineare Modelle, kNN und MLP. Die SVM passt zu stark korrelierten Bändern, weil sie glatte nichtlineare Grenzen lernt; sie braucht standardisierte Eingaben. Baumverfahren sind unempfindlich gegen die Skalierung und dienen als Gegenprobe. Kurzfristig wurde zusätzlich ein einfaches AutoML umgesetzt, das die bisherigen Klassifikatoren, Merkmale und Hyperparameter automatisiert per CV kombiniert (384 Kandidaten aus acht Modellkonfigurationen, sechs Vorverarbeitungen und acht Einstellungen). Es wurde aus Zeit- und Ressourcengründen nicht systematisch untersucht und ist nicht Teil des Pakets `awp2`; die Vorhersage lässt sich separat mit `make predict-automl` erzeugen. Die vollständige Laufhistorie steht im Experimentprotokoll der Projektdokumentation und in MLflow.

4.2 Vergleich und finales Modell

Tabelle 3 stellt die wichtigsten Kandidaten gegenüber. Die Werte stammen aus zwei Splitprotokollen (70/30 bis zum 20. Oktober, danach 80/20) und sind nur innerhalb eines Blocks vergleichbar. CV-Werte sind Mittelwerte der fünf Trainingsfolds, Holdout-Werte einmalige Bewertungen.

Tabelle 3: Wichtigste Kandidaten. Alle Modelle außer der Random-Forest-Baseline sagen nur beobachtete Crop-Stage-Paare vorher. AutoML: Zusatzexperiment, bewertet auf dem bereits betrachteten Holdout. BAcc: Balanced Accuracy; komb.: gemeinsame Crop-Stage-Klasse.

	CV	Holdout-BAcc			Macro-F1
Modell	komb.	Crop	Stage	komb.	komb.
Split 80/20					
Kombiniert, RBF-SVM mit AEZ × Monat	0,864	0,923	0,922	0,869	0,859
Kombiniert, RBF-SVM (AutoML)	0,867	0,932	0,920	0,883	0,858
Hierarchisch, SVM → SVM	0,846	0,918	0,905	0,845	0,827
Kombiniert, GRU (10 Sentinel-2-Bänder)	0,794	0,908	0,890	0,832	0,773
Split 70/30					
Dummy (häufigste Klasse)	–	0,200	0,167	0,044	0,009
Baseline: Random Forest	0,750	0,890	0,870	0,743	0,708
Kombiniert, Random Forest	0,788	0,874	0,876	0,779	0,762
Kombiniert, Extra Trees	0,812	0,886	0,895	0,804	0,796
Kombiniert, RBF-SVM	0,847	0,931	0,906	0,866	0,830
Hierarchisch, SVM → SVM	0,839	0,920	0,902	0,844	0,820
Multi-Task-MLP (PCA-20)	0,728	0,920	0,902	0,765	0,726
Kombiniert, LSTM (Embeddings)	0,711	0,812	0,793	0,700	0,613
Kombiniert, 1D-CNN	0,611	0,819	0,712	0,626	0,559

Die kombinierte RBF-SVM liegt in beiden Protokollen vorn. Im 70/30-Split erreicht sie 0,866 und damit 0,12 mehr als die Baseline und 0,06 mehr als Extra Trees. Die hierarchische SVM bleibt in beiden Protokollen rund 0,02 darunter. Werden die Stadien mit der wahren Kultur angesteuert, steigt sie auf 0,94; der Engpass ist also die Kulturstufe, vor allem Winterweizen gegen Baumwolle und Mais gegen Soja. Weiches Routing, gemischte Klassifikatoren je Stufe und eine gewichtete Abstimmung brachten keinen CV-Gewinn von mindestens 0,005, der vorab als Mindestschwelle festgelegt war.

Das Multi-Task-Netz erreicht bei Kulturart und Stadium fast die SVM, aber nur 0,765 für das Paar. Sequenzmodelle bleiben deutlich zurück; ein GRU auf zehn Sentinel-2-Bändern ist mit 0,832 das beste davon. Bei rund 4.500 Trainingszeilen bringen die neuronalen Netze keinen Vorteil.

Zur zweiten Untersuchungsfrage: Unter den Zusatzmerkmalen tragen AEZ und Monat am meisten. Ohne sie fällt die SVM in der CV von 0,859 auf 0,787 (Split 80/20). Vegetationsindizes und PCA bringen der SVM keinen Gewinn (Abschnitt 5). SNV verschlechtert sie (CV 0,823 statt 0,847, Split 70/30). Savitzky-Golay-Glättung (hierarchische SVM: 0,842 statt 0,840) und die Monatskodierung (numerisch 0,852, zyklisch 0,849) bleiben unter der Mindestschwelle. Nur AEZ-Monat-Indikatoren verbessern die SVM geringfügig (CV +0,005, Holdout +0,003).

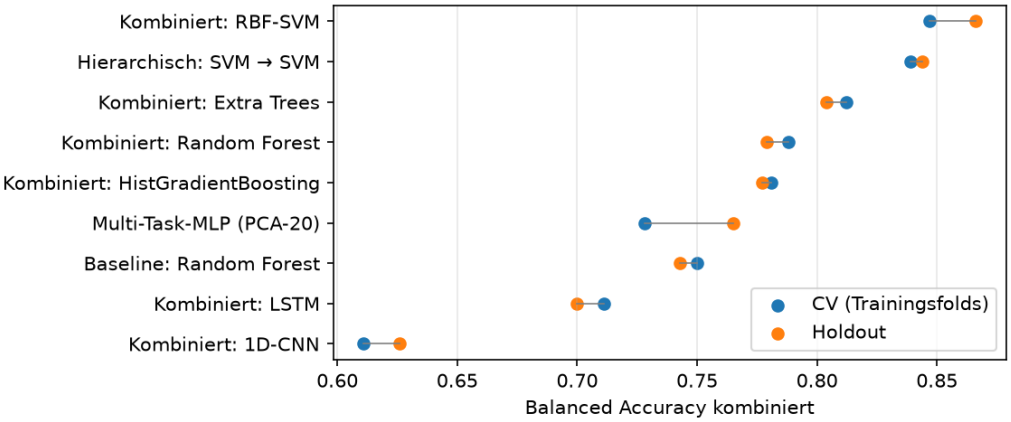


Abbildung 4: CV- und Holdout-BAcc kombiniert der wichtigsten Kandidaten (Split 70/30, nach Holdout sortiert). Die Suchbudgets unterscheiden sich je Modell.

Abbildung 4 zeigt, ob die CV die Holdout-Rangfolge vorhersagt. Die ersten drei Plätze (RBF-SVM, hierarchische SVM, Extra Trees) sind in beiden Maßen gleich. Holdout und CV weichen um höchstens 0,04 voneinander ab, die größte Abweichung zeigt das Multi-Task-MLP. Zwischen Random Forest und HistGradientBoosting (0,779 und 0,777 auf dem Holdout) ist keine Reihenfolge belegt.

Modellwahl. Entscheidend war die CV-BAcc kombiniert; der Holdout dient als ergänzende Bewertung. Zusätzlich zählen beobachtete Paare, geringer Rechenaufwand und Robustheit. Bei unbekannten AEZ-Monat-Zellen ist die hierarchische SVM etwas besser (0,420 statt 0,378), beide Modelle fallen jedoch stark ab (Abschnitt 6). Gewählt wird daher die einfachere kombinierte RBF-SVM auf allen 131 Bändern mit AEZ-Monat-Indikatoren ($C = 300$, $\gamma = 0{,}003$): 0,869 BAcc kombiniert auf dem Holdout.

Das AutoML findet in derselben Modellfamilie mit geglätteten Spektren, Albedo und Indizes eine Variante mit höherer Holdout-BAcc. Ein erneuter Trainingslauf mit identischen Daten und Splits reproduziert CV 0,86682 und Holdout 0,8832; alle 1.118 Holdout-Vorhersagen stimmen exakt überein. Der CV-Gewinn gegenüber der Referenz beträgt jedoch nur etwa 0,003 und unterschreitet die festgelegte Mindestschwelle von 0,005. Das Ergebnis wird deshalb als reproduzierbares Zusatzexperiment berichtet, nicht als unabhängig belegte Verbesserung oder neues Abgabemodell. Eine separate Optuna-Suche erreicht CV 0,867 und Holdout 0,879. Beide Suchen waren adaptiv und der Holdout bereits betrachtet, die Werte sind daher optimistisch.

5 Datenreduktion

Die Datenreduktionsstudie fragt, wie viel spektraler Input für Kulturart und Stadium nötig ist. Untersucht wird sie am besten Modell, der RBF-SVM auf der kombinierten Klasse, und gegengeprüft an der hierarchischen SVM. Alle Zahlen sind kombinierte BAcc nach dem Protokoll aus Abschnitt 3.2.

5.1 Vorgehen

Bänder, Merkmale und Komponenten. Die Studie unterscheidet drei Größen. *Gemessene Bänder* sind die Bänder, die ein Sensor liefern muss. *Merkmale* sind die Spalten, die das Modell sieht, einschließlich AEZ und Monat. *Komponenten* sind die Achsen einer PCA. Eine PCA verringert nur die Zahl der Merkmale: Ihre Komponenten werden aus allen 131 Bändern berechnet,

die weiterhin gemessen werden müssen. Bewertet wird die Reduktion deshalb nach gemessenen Bändern.

Varianten. Tabelle 4 zeigt die geprüften Familien. Ausgewählt wird entweder durch Lage im Spektrum oder datengetrieben. Die Sentinel-2-Variante bildet die zehn 10- und 20-m-Bänder von Sentinel-2 (B2–B8A, B11, B12) nach. Jedes simulierte Band ist der Mittelwert der Hyperion-Bänder innerhalb seiner Bandbreite (Rechtecknäherung).

Tabelle 4: Geprüfte Eingabevarianten der Datenreduktion.

Familie	Varianten	Gemessene Bänder
Alle Bänder	Referenz	131
PCA	2, 5, 10, 20, 40 Komponenten; Zusatzstudie 1–80	131
Univariate Bandauswahl	5, 10, 20, 40, 80 Bänder	5–80
Jedes n-te Band	$n = 2, 4, 8$	66, 33, 17
Sentinel-2-Simulation	10 Oberflächenbänder	10
Nur Indizes	29 Vegetationsindizes	28
Nur Kontext	AEZ und Monat	0

Einbettung und Auswahlregel. Jede Variante ist eine Option der gemeinsamen Vorverarbeitung. PCA und Bandauswahl werden innerhalb der Pipeline nur auf dem jeweiligen Trainingsfold angepasst. AEZ und Monat sind außer in der Kontext-Variante immer enthalten. Jede Variante wird mit demselben Raster für C und γ eigenständig per CV getunt. Die Auswahlregel war vorab festgelegt: Gewählt wird die Variante mit den wenigsten gemessenen Bändern, die höchstens 0,01 CV-BAcc unter der Referenz liegt. Nur diese Variante wird einmal auf dem Holdout bewertet.

5.2 Ergebnisse

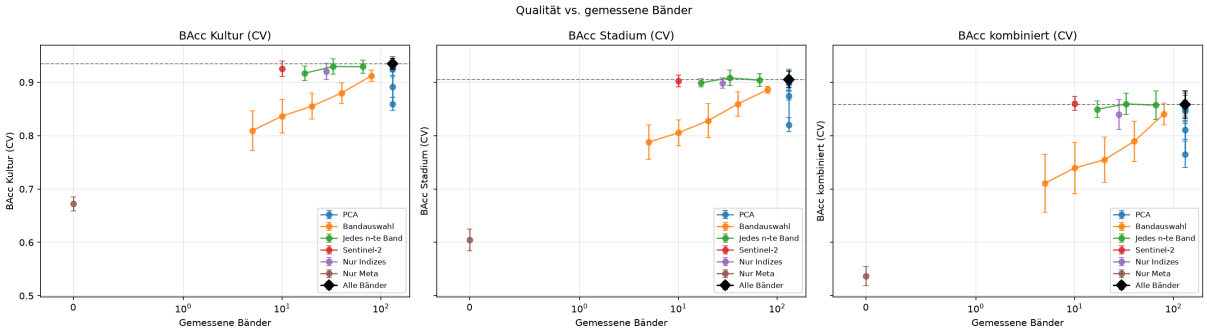


Abbildung 5: CV-BAcc für Kulturart, Stadium und kombinierte Klasse je Anzahl gemessener Bänder (logarithmische Achse; Fehlerbalken: Standardabweichung über die fünf Folds). Schwarze Raute und gestrichelte Linie: alle 131 Bänder. PCA-Varianten liegen immer bei 131 Bändern.

Breite Abdeckung reicht. Abbildung 5 zeigt den Zusammenhang zwischen Leistung und Eingabeumfang. Gleichmäßig verteilte Bänder halten die Leistung fast vollständig: Mit jedem vierten Band (33 Bänder) liegt die CV-BAcc bei 0,859, mit jedem achten Band (17) bei 0,849. Die zehn Sentinel-2-Bänder erreichen 0,860, genauso viel wie alle 131 Bänder (0,859). Nach der Auswahlregel ist Sentinel-2 damit die empfohlene Variante.

Einzelne „beste“ Bänder reichen nicht. Die univariate Bandauswahl erreicht mit zehn Bändern nur 0,739 und selbst mit 80 Bändern nur 0,841. Sie bewertet jedes Band einzeln. Deshalb wählt sie benachbarte, nahezu identische Bänder aus derselben Region und lässt andere Bereiche aus. Eine Bandauswahl getrennt je Ebene des hierarchischen Modells hilft nicht: Bei zehn Bändern je Ebene umfasst die Vereinigung schon 52 Bänder, und die BAcc bleibt bei etwa 0,69. Die Ebenen stützen sich auf verschiedene Spektralregionen; ein Sensor muss daher den Bereich von VIS bis SWIR 2 abdecken.

Kontext und Indizes. AEZ und Monat allein erreichen nur 0,537 und ersetzen die Spektren nicht, sind aber unverzichtbar (Abschnitt 4). Mittlere Albedo oder vorab berechnete Hauptkomponenten bringen nichts zusätzlich. Die 29 Indizes allein erreichen 0,840. Wie nützlich sie sind, hängt vom Modell ab. Die SVM gewinnt durch zusätzliche Indizes nichts (0,848 statt 0,859). Extra Trees, HistGradientBoosting und die logistische Regression verbessern sich dagegen um 0,015 bis 0,029, weil sie aus einzelnen Bändern kein Verhältnis bilden. Sie bleiben trotzdem mindestens 0,03 hinter der SVM.

Validierung. Tabelle 5 vergleicht die nach der Regel gewählten Varianten auf dem Holdout. Bei der kombinierten SVM verlieren die zehn Sentinel-2-Bänder 0,009 kombinierte BAcc bei 92 % weniger gemessenen Bändern. Die Kulturart wird sogar besser erkannt, das Stadium etwas schlechter. Hierarchisch ist das Bild ähnlich. Sentinel-2 lag dort in der CV knapp außerhalb der Regel ($-0{,}012$), wurde aber zum Vergleich mitbewertet.

Tabelle 5: Holdout-Ergebnisse der gewählten Varianten (BAcc; CV: kombiniert im Trainingsanteil).

Ansatz	Eingabe	Bänder	CV	Crop	Stage	komb.
Kombiniert	alle Bänder	131	0,859	0,920	0,913	**0,866**
Kombiniert	Sentinel-2	10	0,860	0,931	0,905	0,857
Hierarchisch	alle Bänder	131	0,846	0,918	0,905	**0,845**
Hierarchisch	jedes 8. Band	17	0,839	0,920	0,910	0,828
Hierarchisch	Sentinel-2	10	0,834	0,930	0,884	0,839

Der Macro-F1 kombiniert fällt mit Sentinel-2 deutlich stärker als die BAcc, von 0,859 auf 0,813. Der Recall bleibt etwa gleich, aber seltene Klassen werden häufiger fälschlich vorhergesagt. So sinkt die Precision von `cotton|Harvest` von 1,00 auf 0,40. Bei nur 2 bis 13 Holdout-Beispielen in diesen Klassen ist dieser Effekt unsicher, schränkt die Empfehlung aber ein.

PCA. Eine Zusatzstudie variiert die Zahl der Komponenten von 1 bis 80, jeweils mit eigenem Tuning und im Fold angepasster PCA (Abbildung 6). Bis fünf Komponenten fällt die Leistung steil ab. Ab acht Komponenten (0,851) liegt sie innerhalb der Auswahlregel, mit Ausnahme von zehn Komponenten (0,846). Innerhalb von $\pm 0{,}005$ um die Referenz liegt sie aber erst ab 30 Komponenten. Hohe erklärte Varianz bedeutet dabei keine Trennkraft: Zwei Komponenten erklären 91,8 % der Varianz und verlieren trotzdem 0,093. Sie bilden vor allem den Kontrast zwischen Vegetation und Boden sowie die Helligkeit ab. Die für die SVM wichtigen Red-Edge-Merkmale tauchen erst in der vierten Komponente auf, die nur 1,1 % der Varianz erklärt.

PCA reduziert die Merkmale der SVM von 140 auf 17, beschleunigt Training und Vorhersage aber nur um etwa den Faktor 1,3. Dabei müssen weiterhin alle Bänder gemessen werden. Nur die logistische Regression profitiert: Mit 20 Komponenten erreicht sie 0,820 statt 0,808 und ist etwa zwölfmal schneller. Auch auf den Sentinel-2-Bändern bringt PCA keinen Vorteil. Vorab

war festgelegt, die PCA-Variante nur dann zu validieren, wenn sie mindestens 0,005 besser oder doppelt so schnell ist. Beides trifft nicht zu, daher gibt es keinen Holdout-Wert.

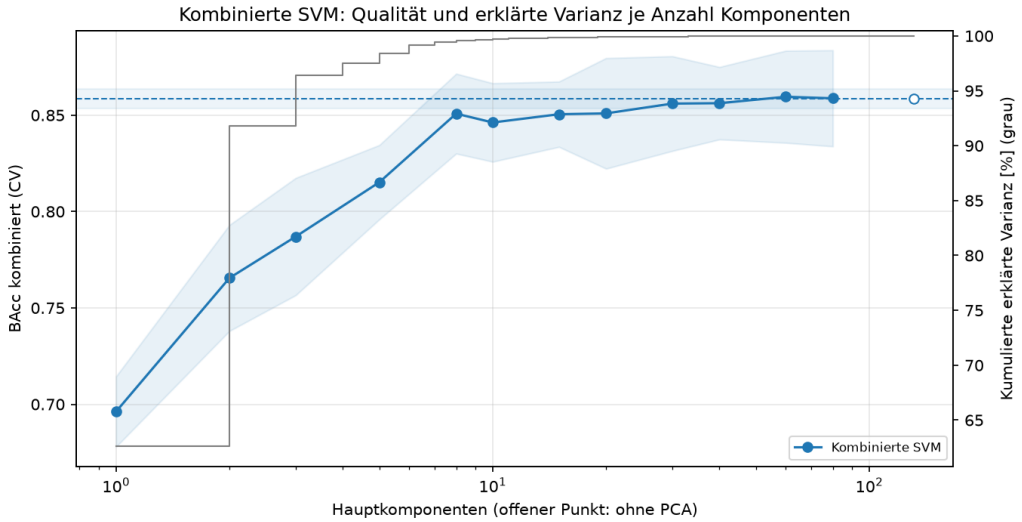


Abbildung 6: Kombinierte SVM: CV-BAcc je Anzahl PCA-Komponenten (Band: Standardabweichung über die Folds) und kumulierte erklärte Varianz (grau, rechte Achse). Gestrichelt: alle Bänder ohne PCA mit ±0,005.

5.3 Bewertung und Grenzen

Trade-off. Zehn breite Bänder an Sentinel-2-Positionen plus AEZ und Monat sind eine vertretbare Reduktion. Sie kosten auf dem Holdout 0,009 kombinierte BAcc und deutlich mehr Macro-F1 in seltenen Klassen. Dafür müssen 92 % weniger Bänder gemessen werden. Wichtiger als hohe spektrale Auflösung ist die Abdeckung aller Bereiche von VIS bis SWIR 2. Die univariate Bandauswahl ist nicht vertretbar, und PCA lohnt sich für die SVM nicht. In der Challenge liegen alle Bänder bereits vor, Messkosten spielen also keine Rolle. Das Endmodell nutzt deshalb weiterhin alle Bänder.

Simulierte statt echter Sentinel-2-Daten. Gezeigt ist nur, dass die spektrale Information an den Sentinel-2-Positionen auf Hyperion-Daten ausreicht. Ob ein auf Hyperion trainiertes Modell auf echten Sentinel-2-Aufnahmen funktioniert, ist nicht geprüft. Die Simulation nähert die Empfindlichkeitskurven durch Rechtecke an; außerdem unterscheiden sich räumliche Auflösung (30 m gegenüber 10 bzw. 20 m), Rauschen (Signal-Rausch-Verhältnis bei 2.125 nm etwa 40 gegenüber etwa 100 im SWIR [2, 3]) und Prozessierung [5]. Da die Aufnahmen aus den Jahren 2008 bis 2015 stammen, gibt es zudem keine gelabelten Sentinel-2-Paare.

Unbekannte AEZ-Monat-Zellen. In der Gruppen-CV (Abschnitt 6) liegt die kombinierte SVM mit Sentinel-2 gleichauf mit allen Bändern (0,389 statt 0,378 für eine unbekannte Zelle, 0,419 statt 0,421 für einen unbekannten Monat, 0,274 statt 0,284 für eine unbekannte Region); am robustesten ist die hierarchische SVM mit Sentinel-2 (0,426, 0,424, 0,294). Die Reduktion verschlechtert die Übertragbarkeit also nicht, löst das Problem aber auch nicht.

6 Ergebnisse und Interpretation

6.1 Vorhersageleistung und Fehleranalyse

Datenbasis. Alle Kennzahlen in diesem Abschnitt stammen vom internen Holdout (1.118 Beobachtungen, Abschnitt 3.2). Das Endmodell wurde dafür mit seinen festen Einstellungen nur auf den 4.471 Trainingszeilen angepasst. Das Abgabemodell nutzt zusätzlich den Holdout. Für `test.csv` gibt es keine Labels, deshalb nennen wir dort keine Gütemaße. Zum Vergleich wurden die Random-Forest-Baseline und die hierarchische SVM mit ihren protokollierten Einstellungen auf demselben 80/20-Split neu trainiert.

Tabelle 6: Holdout-Ergebnisse des Endmodells und der Vergleichsmodelle (Split 80/20).

	BAcc			Macro-F1			Samples-F1
Modell	Crop	Stage	komb.	Crop	Stage	komb.	
Baseline: Random Forest	0,898	0,870	0,751	0,875	0,863	0,693	0,879
Hierarchisch, SVM → SVM	0,918	0,905	0,845	0,900	0,897	0,827	0,906
Endmodell: komb. RBF-SVM	**0,923**	**0,922**	**0,869**	**0,910**	**0,923**	**0,859**	**0,920**

Leistung und Abstand zur Baseline. Tabelle 6 fasst die Ergebnisse zusammen. Gegenüber der Baseline gewinnt es 0,118 kombinierte BAcc und 0,166 Macro-F1. Bei den Einzelzielen steigt das Stadium (+0,052) stärker als die Kulturart (+0,025). Das Endmodell sagt nur beobachtete Paare voraus, die Baseline zu 0,3 % nicht beobachtete.

Wie sicher ist der Vorsprung? Der Holdout umfasst nur 1.118 Zeilen, und seltene Klassen gehen mit wenigen Fällen in die BAcc ein. Ein anderer Holdout hätte also leicht andere Werte ergeben. Um diese Unsicherheit zu zeigen, haben wir 1.000-mal Holdout-Zeilen mit Zurücklegen gezogen (Bootstrap). Für jede Ziehung wurde die kombinierte BAcc aller drei Modelle berechnet. Abbildung 7 zeigt die Bereiche, in denen 95 % der Ziehungen liegen. Der Vorsprung auf die Baseline beträgt 0,07 bis 0,16 und ist in jeder Ziehung positiv. Er ist also kein Zufall der Zeilenauswahl. Auch zeilenweise ist das Bild klar: 108 Zeilen trifft nur das Endmodell, 30 nur die Baseline. Der Vorsprung auf die hierarchische SVM liegt dagegen zwischen 0,00 und 0,05 (47 gegen 26 Zeilen). Er ist in 97 % der Ziehungen positiv, aber klein. Beide Ansätze sind deshalb nahezu gleichwertig. Für das kombinierte Modell sprechen der kleine Vorsprung und der einfachere Aufbau. Der Holdout wurde bei der Modellwahl schon mehrfach betrachtet, die Intervalle sind deshalb eher zu optimistisch.

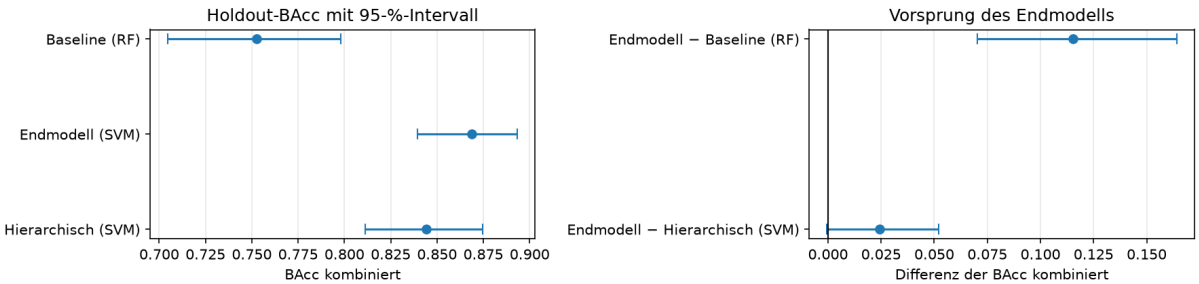


Abbildung 7: Kombinierte BAcc auf dem Holdout (links) und Vorsprung des Endmodells (rechts). Punkt: Median, Balken: 95 % der 1.000 Bootstrap-Ziehungen. Liegt ein Balken rechts der Nulllinie, ist das Endmodell in fast allen Ziehungen besser.

Wo die Fehler entstehen. Das Endmodell sagt 89,1 % der Zeilen vollständig richtig voraus. Bei 8,0 % ist die Kulturart falsch, bei 2,9 % nur das Stadium. Rund drei Viertel der Fehler sind also Kulturfehler. Bei der Baseline sind es knapp zwei Drittel, sie verfehlt deutlich mehr Stadien. Stimmt die Kulturart, liegt die Stadium-BAcc des Endmodells bei 0,965. Wie bei der hierarchischen SVM (Abschnitt 4) ist die Kulturstufe der Engpass.

Abbildung 8 zeigt die Verwechslungen. Am häufigsten wird Soja für Mais gehalten (22 Zeilen). Es folgen Winterweizen als Baumwolle (17) und Mais als Soja (12). Winterweizen hat mit 0,874 den niedrigsten Kultur-Recall, `Mature_Senesc` mit 0,859 den niedrigsten Stadium-Recall. Von den 32 reinen Stadiumfehlern betreffen 21 innerhalb der Kultur benachbarte Stadien; auffällig ist Soja `Critical` gegen `Mature_Senesc` (10 Zeilen).

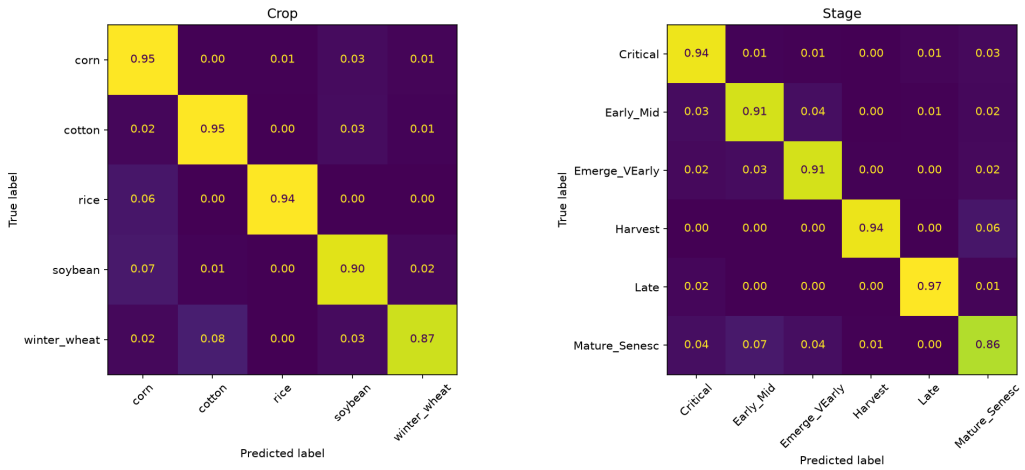


Abbildung 8: Zeilennormierte Confusion Matrices des Endmodells für Kulturart (links) und Stadium (rechts) auf dem Holdout. Die Diagonale ist der Recall je Klasse.

Schwache und seltene Klassen. Abbildung 9 stellt den Recall jeder kombinierten Klasse ihrer Fallzahl gegenüber. Am schwächsten sind frühe Stadien und die Seneszenz, also Klassen am Rand der Saison. Frühe Soja erkennt das Modell nur in knapp der Hälfte der Fälle (Recall 0,476, Precision 0,625), abgereifte Baumwolle in 0,615. Seltenheit allein erklärt die Schwächen nicht. Die sieben Klassen mit weniger als 20 Holdout-Fällen erreichen im Mittel einen Recall von 0,907, die übrigen 0,852. Bei 2 bis 13 Fällen schwanken die Werte aber stark. So beruht der Recall von 1,00 für `cotton|Harvest` auf nur zwei Zeilen.

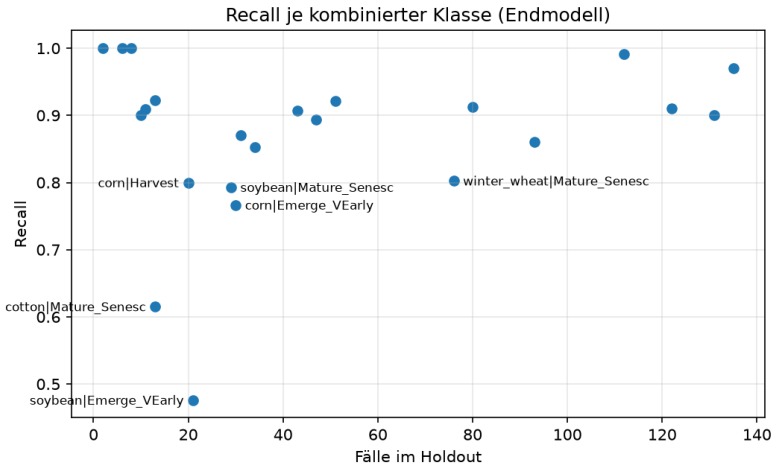


Abbildung 9: Recall je kombinierter Klasse gegen ihre Fallzahl im Holdout (Endmodell). Beschriftet sind die sechs Klassen mit dem niedrigsten Recall.

Saisonränder und Regionen. Abbildung 10 zeigt, dass sich die Kulturfehler zeitlich und räumlich häufen. Im Mai ist bei 21 % der Zeilen die Kulturart falsch, im Juni bei 16 % und im Oktober bei 13 %. Von Juli bis September sind es nur 3,5 bis 5,3 %. In AEZ 9 liegt der Anteil bei 14 % (285 Zeilen), in AEZ 7 ebenfalls, dort aber bei nur 28 Zeilen. In AEZ 8 und AEZ 10 bleibt er unter 4 %. Out-of-fold-Vorhersagen auf dem Trainingsanteil zeigen dasselbe Muster (Mai 21 %, Oktober 15 %, AEZ 9 12 %). Es ist also kein Zufall des Holdouts. Eine plausible, aber nicht geprüfte Erklärung: Am Saisonanfang bedeckt der Bestand wenig Boden, am Ende ist er abgereift oder geerntet. Das Signal wird dann vom Boden geprägt, und die Spektren der Kulturen gleichen sich an.

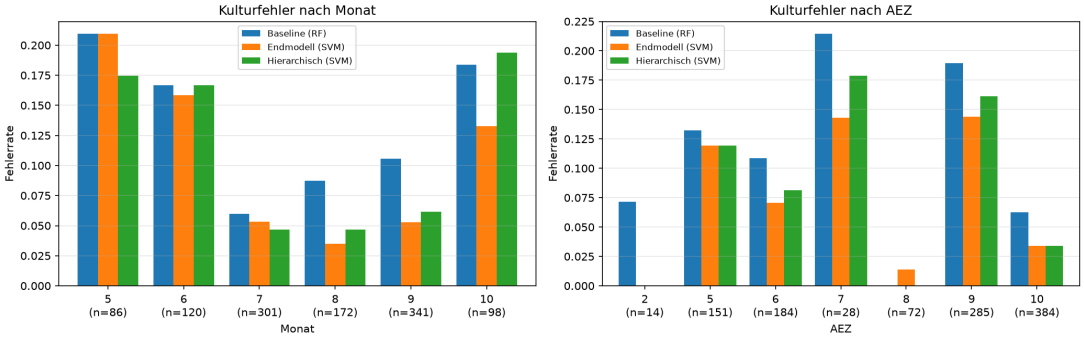


Abbildung 10: Anteil der Holdout-Zeilen mit falscher Kulturart nach Monat (links) und AEZ (rechts) für Baseline, Endmodell und hierarchische SVM.

Übertragbarkeit. Alle Werte gelten für bekannte Kombinationen aus AEZ und Monat, in denen auch die Testdaten liegen. In einer Gruppen-CV, die ganze Zellen zurückhält, fällt die kombinierte SVM (ohne AEZ-Monat-Indikatoren) von 0,859 auf 0,378 (Abbildung 11). Für einen unbekannten Monat erreicht sie 0,421, für eine unbekannte Region 0,284. Das Modell ist deshalb nicht ohne neue Labels auf andere Regionen oder Zeitpunkte übertragbar.

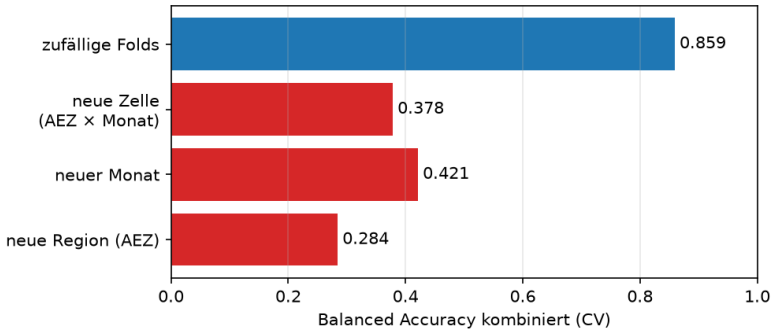


Abbildung 11: Kombinierte CV-BAcc der SVM mit allen Bändern bei zufälligen Folds (blau) und bei Folds, die ganze AEZ-Monat-Zellen, Monate oder Regionen zurückhalten (rot).

6.2 Fachliche Einordnung und Erklärbarkeit

Verfahren. Welche Eingaben das Modell nutzt, wurde mit Permutation Importance untersucht. Dazu wird je CV-Fold eine Merkmalsgruppe im Testfold zufällig vertauscht. Gemessen wird der Abfall der BAcc. Die Gruppen sind sieben Spektralregionen sowie AEZ und Monat. Zusätzlich wurde jedes Band einzeln vertauscht. Die Analyse nutzt nur den Trainingsanteil, der Holdout bleibt unberührt. Gegenstand ist die kombinierte RBF-SVM ohne AEZ-Monat-Indikatoren. Sie gehört zur selben Modellfamilie wie das Endmodell, ist aber nicht identisch mit ihm. Als zweite Methode erklärt KernelSHAP die Entscheidungsfunktion derselben SVM für dieselben neun Gruppen. Die Rangfolge der Gruppen stimmt nahezu überein (Spearman-Korrelation 0,95).

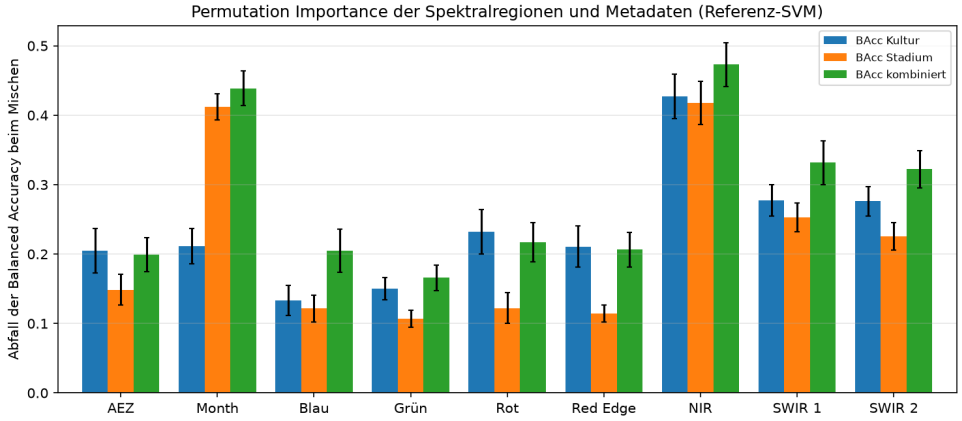


Abbildung 12: Permutation Importance je Gruppe: Abfall der CV-BAcc für Kulturart, Stadium und Paar, wenn die Gruppe vertauscht wird (Fehlerbalken: Standardabweichung über 25 Wiederholungen).

Gemessene Befunde. Abbildung 12 zeigt die Wichtigkeit je Gruppe. Am wichtigsten sind das NIR (Abfall 0,473) und der Monat (0,439). Es folgen SWIR 1 und SWIR 2 (je etwa 0,33). Die übrigen Gruppen liegen zwischen 0,17 und 0,22. Kulturart und Stadium nutzen dabei verschiedene Information. Für die Kulturart zählen vor allem NIR und SWIR, für das Stadium NIR und Monat (Abfall jeweils etwa 0,41). Je Kulturart unterscheiden sich die wichtigsten Bereiche: Für Mais und Baumwolle ist es das SWIR 2, für Reis, Soja und Winterweizen das NIR.

Einzelne Bänder sind kaum wichtig. Der größte Einzelwert beträgt nur 0,038 (722 nm), während ganze Regionen bis zu 0,47 kosten. Benachbarte Bänder ersetzen sich gegenseitig, deshalb unterschätzen Einzelwerte die Bedeutung einer Region. Die einzige zusammenhängende Spitze liegt in der Red Edge bei 712–742 nm, also beim steilen Anstieg der Vegetationsreflexion. Nur

dort zeigen mehrere benachbarte Bänder zugleich erhöhte Werte. Umgekehrt hängt die Größe einer Region mit ihrer Wichtigkeit zusammen. Das NIR umfasst 44 Bänder, die Red Edge nur sieben. Neu trainierte Modelle trennen beide Effekte. Mit AEZ und Monat erreicht die Red Edge allein 0,792, das NIR allein 0,811. Ohne eine einzelne Region ändert sich die Leistung nur um $-0{,}007$ bis $+0{,}003$. Keine Region ist also allein unverzichtbar, was zur breiten Abdeckung aus Abschnitt 5 passt.

Fachliche Deutung. Die Befunde passen zu bekannten Wirkungen auf die Reflexion, sind aber nicht kausal belegt. NIR und Red Edge hängen mit Blattstruktur, Biomasse und Chlorophyll zusammen und damit mit dem Entwicklungsstand. Das SWIR 2 reagiert auf Wasser, Lignin und Cellulose, also auf Trocknung und Reife. Das passt zu seiner Rolle bei Mais und Baumwolle. Gezielt geprüft ist dieser Zusammenhang nicht. Gegen die Erwartung liefern die sichtbaren Bänder, in denen Chlorophyll absorbiert, nur einen mittleren Beitrag.

Grenzen der Erklärung. Vertauschte Zeilen sind keine realistischen Spektren. Die Werte zeigen deshalb, was das Modell nutzt, aber keinen Kausalzusammenhang. Der Monat ist ein Kontextmerkmal. Seine hohe Wichtigkeit für das Stadium spiegelt den Saisonverlauf wider und kann als Abkürzung wirken. Das zeigt sich am Abfall in der Gruppen-CV bei unbekannten Monaten. Reis und seltene Stadien beruhen auf wenigen Zeilen und schwanken stärker.

7 Modellkarte

Die Modellkarte fasst das offizielle Modell der Abgabe zusammen.

Modelldetails	
Modell	Kombinierte RBF-SVM: Kulturart und Stadium werden als eine von 23 Klassen (`Crop|Stage`) vorhergesagt; $C = 300$, $\gamma = 0{,}003$, ausgeglichene Klassengewichte.
Entwickelt von	Team AE-ROOT, Domänenprojekt 2 (WS 2026/27), Oktober 2026.
Version	MLflow-Run `17dc9e16`, Code-Stand Commit `4ed4181`. Es gibt kein gespeichertes Modell; die AutoML-Variante (Run `c99e3915`) ist nur als Zusatzexperiment archiviert.
Nutzung	`make predict` trainiert das deterministische Modell neu und schreibt die Vorhersage-CSV für `test.csv`.
Verwendung	
Vorgesehen	Vorhersage von Kulturart und Stadium aus Hyperion-Spektren in den Zonen und Monaten der Trainingsdaten.
Nicht vorgesehen	Operativer Einsatz sowie andere Sensoren, Regionen oder Jahre.
Daten und Training	
Eingabe	198 Bandspalten (Reflexion in %, 427–2.395 nm), davon 131 nutzbar, sowie `AEZ` (2, 5–10) und `Month` (Mai bis Oktober).
Verarbeitung	Interpolation einzelner Lücken, Standardisierung der Bänder, AEZ one-hot, Monat als Sinus/Kosinus, ein Indikator je beobachteter AEZ-Monat-Zelle (32): 172 Merkmale, alle im Training angepasst.
Training	Alle 5.589 bereinigten Zeilen aus `train.csv`. Die Hyperparameter stammen aus der 5-fach-CV im Trainingsanteil.
Ausgabe	Eines der 23 beobachteten Crop-Stage-Paare; keine Wahrscheinlichkeit oder Unsicherheitsangabe.
Evaluation	
Daten	Holdout mit 1.118 Zeilen (20 %, stratifiziert, Seed 42), Modell nur auf den restlichen 4.471 Zeilen trainiert.
Ergebnis	BAcc Crop 0,923, Stage 0,922, kombiniert 0,869; Macro-F1 kombiniert 0,859; Samples-F1 0,920. CV: BAcc kombiniert 0,864.
Erwartung	Auf `test.csv`: BAcc kombiniert etwa 0,87 (grob 0,83–0,90), Crop und Stage je etwa 0,92; nicht gemessen, Begründung in Abschnitt 8.
Annahmen, Grenzen und Risiken	
Annahmen	Neue Spektren stammen vom selben Sensor, haben dieselbe Bandbelegung und Einheit, liegen in bekannten AEZ-Monat-Zellen und folgen derselben Verteilung; die bereitgestellten Labels werden als korrekt angenommen.
Evaluation	Mehrere Ansätze wurden auf demselben Holdout verglichen; er ist keine unabhängige Abschlussprüfung.
Kontext	Ohne `AEZ` und `Month` sinkt die CV-BAcc von 0,859 auf 0,787. Für neue AEZ-Monat-Zellen, Monate oder Regionen fällt sie auf 0,28–0,42 (Abschnitt 6); `test.csv` liegt in bekannten Zellen.
Fehler	Meist Kulturfehler, vor allem Winterweizen zu Baumwolle und Sojabohne zu Mais, besonders am Saisonrand (Mai, Juni, Oktober). Seltene Klassen sind unsicher: `cotton|Harvest` hat 11 Trainingszeilen, Reis 93.
Nicht geprüft	Kalibrierung, Ablehnung unbekannter Eingaben, Praxistests und echte Sentinel-2-Daten. Nicht beobachtete Paare werden nie vorhergesagt.

8 Fazit und Ausblick

Die kombinierte RBF-SVM sagt Kulturart und Stadium unter vergleichbaren Bedingungen am zuverlässigsten vorher. Auf dem Holdout erreicht sie eine BAcc von 0,923 für die Kulturart, 0,922 für das Stadium und 0,869 für das Paar. Das sind 0,118 mehr als die Baseline und 0,024 mehr als die hierarchische SVM; neuronale Netze bringen bei rund 4.500 Trainingszeilen keinen Vorteil. Den größten Zusatznutzen liefern AEZ und Monat, ohne sie fällt die SVM von 0,859 auf 0,787. Abgeleitete Merkmale wie Indizes, SNV oder PCA helfen ihr dagegen nicht. Der Eingabeumfang lässt sich stark verringern: Zehn breite Bänder an Sentinel-2-Positionen kosten rund 0,01 BAcc bei 92 % weniger gemessenen Bändern. Entscheidend ist also die Abdeckung von VIS bis SWIR 2, nicht die spektrale Auflösung. Das AutoML-Modell des kurzfristigen Zusatzexperiments erreicht auf dem Holdout 0,883, bleibt in der CV aber unter der Mindestschwelle; Abgabemodell ist daher die kombinierte SVM.

Für `test.csv` erwarten wir eine kombinierte BAcc von etwa 0,87 (grob 0,83 bis 0,90) und je etwa 0,92 für Kulturart und Stadium. Gemessen ist das nicht, denn die Testdaten haben keine Labels. Mit 1.397 von 6.988 Zeilen (20,0 %) ist `test.csv` offenbar ein zufälliger Split derselben Daten: Alle Testzeilen liegen in den 32 bekannten AEZ-Monat-Zellen, die Reflexion ist ähnlich verteilt, und die vorhergesagten Kulturanteile weichen um höchstens 1,2 Prozentpunkte vom Training ab. Damit gilt die Situation von CV (0,864) und Holdout (0,869), nicht der Einbruch der Gruppen-CV. Zudem lernt das Abgabemodell auf 5.589 statt 4.471 Zeilen, und die AutoML-Variante sagt für 93,1 % der Testzeilen dasselbe Paar vorher. Die Vorhersage hängt also kaum an der Konfiguration. Das Intervall ist trotzdem breit, weil seltene Klassen wie `cotton|Harvest` (drei vorhergesagte Testzeilen) die BAcc stark bewegen, und eher optimistisch, weil der Holdout an Modellvergleichen beteiligt war. Die meisten Fehler erwarten wir wie im Holdout bei Winterweizen gegen Baumwolle und Soja gegen Mais am Saisonrand.

Die wichtigste Grenze ist die Übertragbarkeit: Für unbekannte AEZ-Monat-Zellen, Monate oder Regionen fällt die BAcc auf 0,28 bis 0,42, und Sentinel-2 ist nur simuliert. Das Modell gibt zudem keine Unsicherheit aus. Nächste Schritte wären Kontrollexperimente zur Sentinel-2-Simulation (echte Empfindlichkeitskurven, Verschiebung und Rauschen) und eine Prüfung auf echten Sentinel-2-Aufnahmen.

Literatur

[1] Mulla, D. J. (2013). Twenty five years of remote sensing in precision agriculture: Key advances and remaining knowledge gaps. *Biosystems Engineering*, 114(4), 358–371. `https://doi.org/10.1016/j.biosystemseng.2012.08.009`.

[2] Pearlman, J., Segal, C., Clancy, P. et al. (2001). *The EO-1 Hyperion Imaging Spectrometer.* IEEE Aerospace Conference (Foliensatz). `https://www.ugpti.org/smartse/research/citations/downloads/Pearlman-Hyperion_IEEE-2001.pdf`.

[3] ESA (o. J.). *S2 Mission.* SentiWiki, Copernicus. `https://sentiwiki.copernicus.eu/web/s2-mission`.

[4] NASA (2025). *Earth Observing-1.* NASA Earth Observatory. `https://science.nasa.gov/earth/earth-observatory/earth-observing-1`.

[5] Aneece, I. & Thenkabail, P. (2018). Accuracies achieved in classifying five leading world crop types and their growth stages using optimal Earth Observing-1 Hyperion hyperspectral narrowbands on Google Earth Engine. *Remote Sensing*, 10(12), 2027. `https://doi.org/10.3390/rs10122027`.

[6] Thenkabail, P. & Aneece, I. (2019). *Global Hyperspectral Imaging Spectral-library of Agricultural crops for Conterminous United States V001* [Datensatz]. NASA Land Processes Distributed Active Archive Center. `https://doi.org/10.5067/COMMUNITY/GHISA/GHISACONUS.001`.