Abschlussbericht
Kulturpflanzen- und Entwicklungsstadiumsklassifikation

Domänenprojekt 2
Team: AE-ROOT

Stand: 30. Oktober 2026

Inhaltsverzeichnis

1 Ziel und Domäne **2**

1.1 Aufgabe und Motivation 2

1.2 Hyperspektrale Messungen und Kulturentwicklung 2

1.3 Untersuchungsziele und Abgrenzung 2

2 Daten und explorative Analyse **3**

2.1 Datengrundlage und Zielgrößen 3

2.2 Zentrale Befunde und Konsequenzen 3

3 Methodik und Validierung **5**

3.1 Datenaufbereitung und Merkmalsbildung 5

3.2 Evaluationsprotokoll und Reproduzierbarkeit 6

4 Modellvergleich und Auswahl **7**

4.1 Baseline und untersuchte Strategien 7

4.2 Vergleich und finales Modell 7

5 Datenreduktion **7**

6 Ergebnisse und Interpretation **7**

6.1 Vorhersageleistung und Fehleranalyse 7

6.2 Fachliche Einordnung und Erklärbarkeit 7

7 Modellkarte **8**

8 Fazit und Ausblick **9**

A Ergänzende Ergebnisse und Reproduktion **9**

1 Ziel und Domäne

1.1 Aufgabe und Motivation

Ziel des Projekts ist die gemeinsame Vorhersage der Kulturart (`Crop`) und ihres Entwicklungsstadiums (`Stage`) aus hyperspektralen Satellitenmessungen. Die Aufgabe wird als Challenge bearbeitet, in der alle Teams dieselbe Klassifikationsaufgabe untersuchen. Neben der Vorhersageleistung verlangt die Aufgabenstellung einen begründeten Vergleich verschiedener Modellierungsstrategien und eine Untersuchung des Zielkonflikts zwischen Datenreduktion und Klassifikationsleistung [1].

Die Kulturart beschreibt, was auf einer Fläche wächst; das Entwicklungsstadium ordnet die Beobachtung in den saisonalen Verlauf ein. Solche Informationen können landwirtschaftliches Monitoring, Agrarstatistik und die Planung von Bewirtschaftungsmaßnahmen unterstützen. Fernerkundung ermöglicht dabei die wiederholte Beobachtung großer oder schwer zugänglicher Gebiete und kann Feldbegehungen ergänzen [2]. Das vorliegende Projekt untersucht jedoch die Klassifikationsleistung auf den bereitgestellten Daten. Ob daraus ein praktischer Nutzen etwa für Bewässerung, Düngung oder Ernteplanung entsteht, wird nicht nachgewiesen.

1.2 Hyperspektrale Messungen und Kulturentwicklung

Ein Spektrum beschreibt die Reflexion einer Oberfläche über verschiedene Wellenlängen. Hyperspektrale Sensoren erfassen viele schmale Spektralbänder und können dadurch feine Unterschiede im Reflexionsverhalten abbilden. Grundlage der Aufgabe sind Messungen des Sensors Hyperion an Bord des Satelliten Earth Observing-1 (EO-1). Hyperion erfasste 220 Bänder im Bereich von etwa 400 bis 2.500 nm bei einer nominellen räumlichen Auflösung von 30 m [3]. Davon zu unterscheiden sind die 198 bereitgestellten Bandspalten zwischen 427 und 2.395 nm. Ihre Reihenfolge beschreibt die Wellenlängenachse einer Beobachtung, keine Zeitreihe.

Bei grüner Vegetation absorbieren Blattpigmente vor allem blaues und rotes Licht. Der starke Anstieg zum nahen Infrarot wird als Red Edge bezeichnet; die hohe Reflexion im nahen Infrarot hängt wesentlich mit der inneren Blattstruktur zusammen. Im kurzwelligen Infrarot beeinflussen unter anderem der Wassergehalt und trockene Pflanzenbestandteile das Signal. Mit der Kulturentwicklung verändern sich außerdem Blattfläche, Bodenbedeckung und Pflanzenhöhe. Diese Zusammenhänge motivieren die Klassifikation anhand spektraler Signaturen, garantieren aber keine eindeutige Trennung: Bodenanteile, Aufnahmebedingungen und Unterschiede innerhalb einer Kultur können ebenfalls zum gemessenen Spektrum beitragen.

Unterschieden werden Mais, Sojabohne, Winterweizen, Baumwolle und Reis sowie sechs Stadienkategorien: `Emerge_VEarly`, `Early_Mid`, `Critical`, `Late`, `Mature_Senesc` und `Harvest`. Diese Labels werden als vorgegebene Kategorien behandelt, nicht als bestätigte Zuordnung zu standardisierten phänologischen Skalen. Zusätzlich stehen die agroökologische Zone (`AEZ`) und der Aufnahmemonat (`Month`) als Kontextmerkmale zur Verfügung. Agroökologische Zonen gruppieren Gebiete nach natürlichen Anbaubedingungen wie Klima, Böden und Vegetationsperiode [1].

1.3 Untersuchungsziele und Abgrenzung

Die Modellierung muss ungleiche Klassenhäufigkeiten, seltene Crop-Stage-Paare und mögliche spektrale Überlappungen berücksichtigen. Kulturart und Stadium sind dabei keine unabhängigen Zielgrößen: Stadien können sich je nach Kultur unterschiedlich im Spektrum ausdrücken. Nicht beobachtete Kombinationen belegen allerdings nicht, dass diese fachlich unmöglich sind. Vor diesem Hintergrund leiten drei Fragen die Untersuchung:

1. Welche Modellierungsstrategie sagt Kulturart und Entwicklungsstadium unter vergleichbaren Evaluationsbedingungen am zuverlässigsten vorher?
2. Welchen zusätzlichen Nutzen liefern AEZ, Aufnahmemonat und abgeleitete Merkmale gegenüber den Spektralbändern allein?
3. Wie weit lässt sich der Eingabeumfang reduzieren, und welcher Verlust an Klassifikationsleistung entsteht dabei?

Die primäre Bewertungsmetrik ist die Balanced Accuracy, die den Recall gleichgewichtet über die Klassen mittelt. Ergänzend werden Macro-F1 und Samples-F1 betrachtet. Kulturart und Stadium werden jeweils separat ausgewertet; die gemeinsame Vorhersage wird zusätzlich untersucht [1]. Die Ergebnisse gelten zunächst für die untersuchte Datenbasis. Eine Übertragbarkeit auf andere Regionen, Jahre oder Sensoren und die Eignung für einen operativen Einsatz sind damit nicht belegt.

2 Daten und explorative Analyse

2.1 Datengrundlage und Zielgrößen

Die Daten entsprechen in Aufbau und Labels der hyperspektralen Bibliothek GHISACONUS für die USA [5, 4]: fünf Kulturarten, sechs Entwicklungsstadien und sieben agroökologische Zonen aus Hyperion-Aufnahmen der Jahre 2008 bis 2015. Je Feld wurde dort ein Pixel abseits des Feldrandes ausgewählt, mit einem Atmosphärenmodell (SMARTS) in Bodenreflektanz umgerechnet und über drei benachbarte Bänder geglättet [4]. Welche Aufnahmen die Challenge daraus ausgewählt hat und wie die Codes von `AEZ` genau definiert sind, ist nicht dokumentiert.

Eine Zeile beschreibt ein Spektrum: 198 Reflektanzwerte in Prozent zwischen 427 und 2.395 nm sowie die Kontextmerkmale `AEZ` (Zonen 2 und 5–10) und `Month` (Mai bis Oktober). Die gelabelte Datei `train.csv` umfasst 5.591 Beobachtungen und dient der gesamten Entwicklung; die ungelabelte Datei `test.csv` mit 1.397 Beobachtungen wird nur für die finale Vorhersage verwendet, ihre Labelverteilung ist unbekannt. Tabelle 1 zeigt die Zielgrößen. Von 30 denkbaren Kombinationen aus Kultur und Stadium kommen 23 vor. Fehlende Paare sind ein Befund der Stichprobe, keine fachliche Unmöglichkeit; Vorhersagen werden dennoch auf die beobachteten Paare beschränkt.

Tabelle 1: Beobachtungen je Kultur und Stadium in `train.csv` (vor der Duplikatbereinigung).

Kultur	Emerge_VEarly	Early_Mid	Critical	Late	Mature_Senesc	Harvest	Summe
corn	152	212	675	557	399	102	2.097
soybean	106	465	652	233	146	67	1.669
winter_wheat	608	–	56	30	379	–	1.073
cotton	172	253	158	–	65	11	659
rice	–	52	–	41	–	–	93
Summe	1.038	982	1.541	861	989	180	5.591

2.2 Zentrale Befunde und Konsequenzen

Starkes Klassenungleichgewicht. Mais und Sojabohne stellen zwei Drittel der Daten, Reis nur 93 Beobachtungen. Das seltenste Paar `cotton|Harvest` hat 11 Beobachtungen. Deshalb wird nach `Crop|Stage` stratifiziert, Balanced Accuracy und Macro-F1 ersetzen die einfache Accuracy, und die Modelle gewichten Klassen ausgeglichen (Abschnitt 3.2). Werte für seltene Paare bleiben unsicher.

Datenqualität. In beiden Dateien sind dieselben 67 Bandspalten vollständig leer, vor allem in den Wasserabsorptionsbereichen um 950, 1.130, 1.400 und 1.900 nm und an den Rändern. Es bleiben 131 Bänder in fünf zusammenhängenden Abschnitten (437–923, 983–1.094, 1.175–1.316, 1.518–1.760 und 2.063–2.345 nm). Einzelne Werte fehlen nur in 44 Trainings- und 11 Testzeilen, ohne Häufung in einer Gruppe. Zwei Paare von Trainingszeilen sind exakt identisch; zwischen Training und Test gibt es keine identischen Eingaben. Daraus folgen das Entfernen leerer Bänder und der Duplikate sowie die Interpolation entlang der Wellenlänge (Abschnitt 3.1). Das Reflexionsniveau ist im Blauen mit einem Median von etwa 16 % deutlich höher als für Vegetation an der Oberfläche üblich; die Werte enthalten offenbar noch einen Atmosphären- oder Kalibrieranteil. Eine Regelprüfung mit relativen Schwellen markiert 5,5 % der Zeilen als spektrale Ausreißer ihrer Klasse. Sie bündeln sich in einzelnen kleinen Aufnahmen mit hellen, bodenartigen Spektren und sind damit eher echte Beobachtungen als Messfehler; sie werden nicht entfernt.

Spektren unterscheiden sich, überlappen aber. Abbildung 1 zeigt die erwartete Vegetationsform mit Chlorophyllabsorption um 670 nm, steilem Anstieg an der Red Edge und hohem NIR-Plateau. Die Kulturen unterscheiden sich vor allem im NIR (Reis am hellsten, Baumwolle und Winterweizen am dunkelsten) und im SWIR, wo Baumwolle und Winterweizen mit mehr Boden- oder Trockenmasseanteil heller sind. Innerhalb einer Kultur verschieben sich die Stadien besonders im NIR und SWIR. Die Streubereiche überlappen jedoch stark, sodass kein einzelnes Band und keine einzelne Kurve eine Klasse festlegt. Das Helligkeitsniveau selbst trägt Information; eine Normalisierung jedes Spektrums (SNV) verschlechtert die Klassifikation entsprechend.

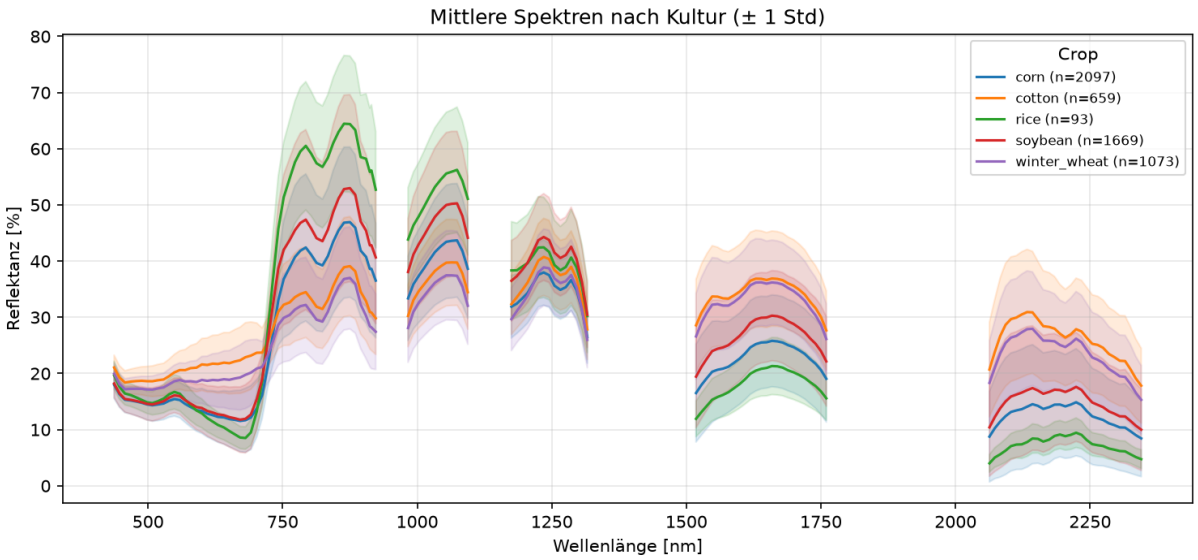


Abbildung 1: Mittlere Spektren je Kultur (± eine Standardabweichung). Lücken markieren vollständig leere Bandbereiche.

Benachbarte Bänder sind redundant. Benachbarte nutzbare Bänder korrelieren im Median mit 0,999. Zwei Hauptkomponenten erklären bereits mehr als 90 % der spektralen Varianz, trennen die Klassen aber nicht. Die größten Unterschiede zwischen Kulturen liegen zwischen 600 und 700 nm, zwischen Stadien am Übergang zum NIR (760–875 nm) und im SWIR. Das begründet die Untersuchung von Dimensionsreduktion und Bandauswahl (Abschnitt **??**); jede solche Auswahl wird nur im Trainingsfold gelernt.

Kontext strukturiert die Labels stark. Die Zonen enthalten sehr unterschiedliche Kulturen: In AEZ 2 kommt nur Baumwolle, in AEZ 8 nur Mais und Reis nur in AEZ 7 vor. Innerhalb

einer Kultur hängt das Stadium eng am Monat (Abbildung 2): Mais im August ist ausschließlich `Critical`, Winterweizen läuft im September und Oktober auf. Die 1.397 Testzeilen liegen in denselben 32 Kombinationen aus Zone und Monat wie das Training. `AEZ` und `Month` sind deshalb starke, zulässige Merkmale, können aber Aufnahme- und Regionseffekte statt spektraler Unterschiede abbilden. Wie stark die Leistung für unbekannte Zonen oder Monate sinkt, prüft die Gruppen-CV (Abschnitt 3.2).

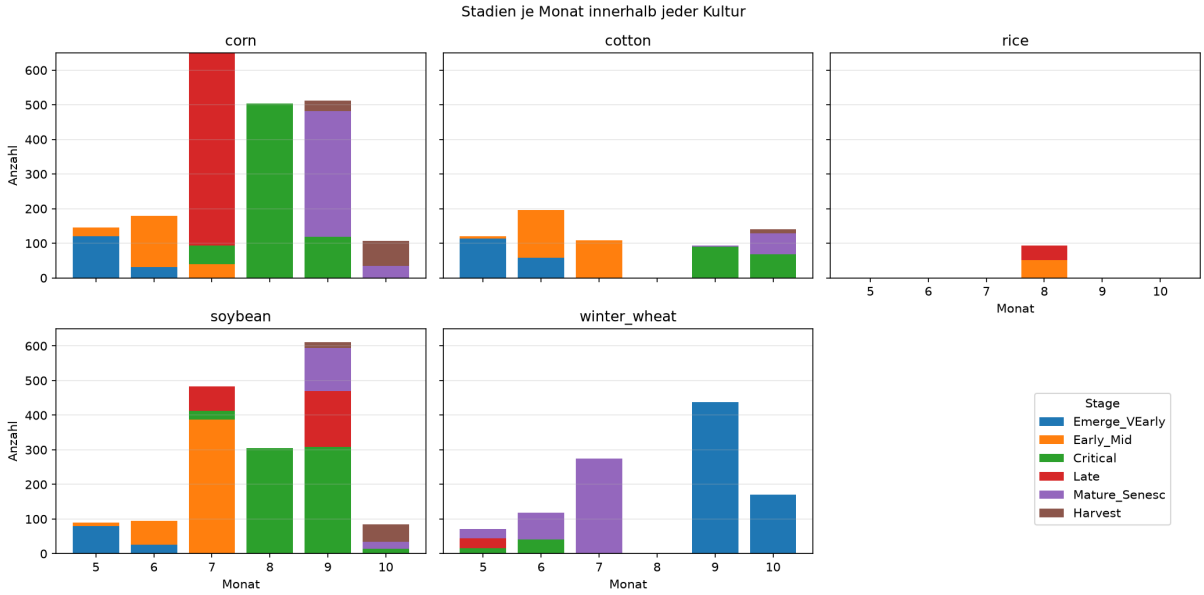


Abbildung 2: Beobachtungen je Monat und Stadium innerhalb jeder Kultur.

3 Methodik und Validierung

Abbildung 3 fasst die Trennung von Modellauswahl und Holdout-Bewertung zusammen.

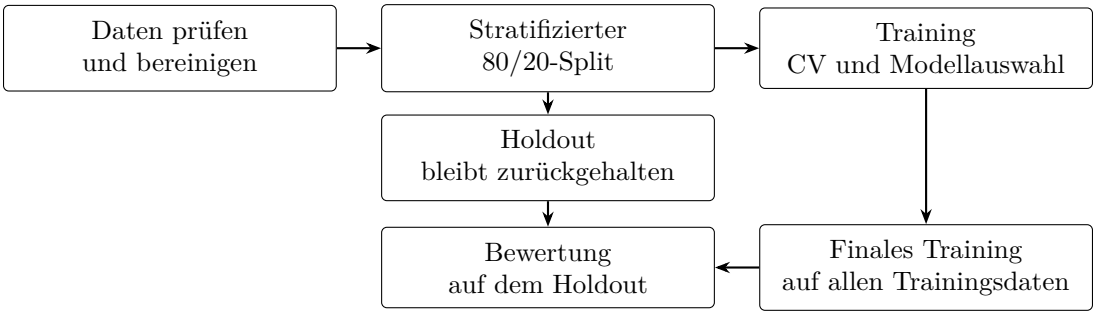


Abbildung 3: Kompakter Ablauf mit getrennter Trainings-CV und Holdout-Bewertung.

3.1 Datenaufbereitung und Merkmalsbildung

Alle Ansätze nutzen die gemeinsame Pipeline des Pakets `awp2`. Die Rohdaten werden auf Format, Wertebereiche und zulässige Labels geprüft. Nach dem Entfernen zweier exakter Duplikate verbleiben 5.589 Beobachtungen. Ausreißer werden nicht pauschal entfernt, da kein ausreichender Nachweis für Messfehler vorliegt. Die Kennung `id` und die Zielspalten sind keine Eingabemerkmale.

Von 198 Bandspalten bleiben nach Ausschluss vollständig leerer Bänder 131 nutzbar. Fehlende Werte werden entlang der Wellenlänge linear interpoliert, wenn die Stützbänder höchstens

15 nm auseinanderliegen; sonst wird der nächste Messwert verwendet. Bei vollständig fehlenden Spektren dienen Trainingsmediane als Ersatz. Die Skalierung ist modellabhängig: SVMs erhalten standardisierte Spektren, Baummodelle benötigen dies nicht.

Als Kontextmerkmale dienen `AEZ` und `Month`. Die Zone wird one-hot-kodiert, der Monat standardmäßig zyklisch durch Sinus und Kosinus dargestellt. Ihr Nutzen wird gegen Modelle ohne Metadaten geprüft. Weitere Varianten umfassen Vegetationsindizes, Glättung, spektrale Normalisierung, PCA und Bandauswahl; ihre Ergebnisse folgen im Modellvergleich und bei der Datenreduktion. Sämtliche datenabhängigen Aufbereitungsschritte werden zusammen mit dem Modell nur auf den jeweiligen Trainingsdaten angepasst, nicht auf den zur Bewertung zurückgehaltenen Beobachtungen.

3.2 Evaluationsprotokoll und Reproduzierbarkeit

Aufteilung und Modellauswahl. Tabelle 2 zeigt das aktuelle Standardprotokoll. Die Aufteilung erfolgt mit Seed 42 stratifiziert nach `Crop|Stage`, damit auch seltene Zielpaare in beiden Teilen vertreten sind. Alle Ansätze laden dieselbe gespeicherte Zuordnung.

Tabelle 2: Gemeinsame Datenaufteilung nach der Duplikatbereinigung.

Bestandteil	Umfang bzw. Verwendung
Training	4.471 Beobachtungen (80 %)
Interner Holdout	1.118 Beobachtungen (20 %)
Trainings-CV	5 Folds innerhalb des Trainingsanteils

Hyperparameter und Merkmalsvarianten werden mit stratifizierter Cross-Validation (CV) ausschließlich im Trainingsanteil verglichen. Dabei wird jeweils auf vier Teilmengen trainiert und auf der fünften bewertet. Die Auswahl erfolgt anhand der mittleren kombinierten Balanced Accuracy. Anschließend wird die gewählte Pipeline auf dem gesamten Trainingsanteil angepasst und auf dem Holdout bewertet. Neuronale Modelle nutzen zusätzlich einen internen Trainingsanteil für frühes Stoppen. CV- und Holdout-Ergebnisse werden getrennt berichtet; ältere 70/30-Läufe sind nicht direkt mit dem aktuellen Protokoll vergleichbar.

Bewertungsmetriken. Die Hauptmetrik ist die **Balanced Accuracy (BAcc)**. Sie mittelt den Recall, also den Anteil richtig erkannter Beobachtungen einer Klasse, gleichgewichtet über die tatsächlichen Klassen. Dadurch erhalten seltene Klassen dasselbe Gewicht wie häufige. Ergänzend wird **Macro-F1** berichtet: der ungewichtete Mittelwert der klassenweisen F1-Werte, die Precision und Recall als harmonisches Mittel verbinden. Mit R_k als Recall und $F1_k$ als F1-Wert der Klasse k gilt jeweils für die K berücksichtigten Klassen:

$$\mathrm{BAcc} = \frac{1}{K}\sum_{k=1}^{K} R_k, \qquad F1_{\mathrm{macro}} = \frac{1}{K}\sum_{k=1}^{K} F1_k.$$

Beide Metriken werden für Kulturart, Stadium und das kombinierte Paar berechnet. Das Klassenungleichgewicht wird je nach Modell durch Klassen- oder Stichprobengewichte beziehungsweise gleiche Klassenprioren berücksichtigt. Confusion Matrices und der Anteil vorhergesagter Paare, die im Training nicht vorkamen, ergänzen die Fehleranalyse.

Grenzen und Nachvollziehbarkeit. Da mehrere Ansätze auf demselben Holdout bewertet wurden, ist dieser keine vollständig unabhängige Abschlussprüfung der Modellwahl. Zusätzliche

Gruppen-CV nach AEZ, Monat oder deren Kombination zeigt deutlich geringere Leistungen bei unbekannten Kontextgruppen. Gute zufällige CV-Ergebnisse belegen daher keine Übertragbarkeit auf neue Regionen oder Zeitpunkte. Ohne Aufnahme- oder Feldkennungen lässt sich auch keine sichere Trennung tatsächlicher Aufnahmen oder Felder nachweisen.

Split-Artefakte, Seed und `uv.lock` stützen die Reproduktion. MLflow dient zur Laufdokumentation; Tracking-Ausfälle und nichtdeterministische Berechnungen bleiben Einschränkungen.

4 Modellvergleich und Auswahl

4.1 Baseline und untersuchte Strategien

4.2 Vergleich und finales Modell

5 Datenreduktion

6 Ergebnisse und Interpretation

6.1 Vorhersageleistung und Fehleranalyse

6.2 Fachliche Einordnung und Erklärbarkeit

7 Modellkarte

Die Modellkarte beschreibt das offizielle Modell der Abgabe: eine RBF-SVM, die Kulturart und Stadium als eine gemeinsame Klasse vorhersagt.

Tabelle 3: Steckbrief des offiziellen Modells.

Modell	Kombinierte RBF-SVM mit 23 Klassen (`Crop|Stage`), $C = 300$, $\gamma = 0{,}003$, ausgeglichene Klassengewichte.
Version	MLflow-Run `17dc9e16`, Code-Stand Commit `4ed4181`. Kein gespeichertes Modell: Das deterministische Training läuft mit `make predict`.
Einsatzzweck	Vorhersage von Kulturart und Stadium für `test.csv`. Nicht geprüft: operativer Einsatz sowie andere Sensoren, Regionen oder Jahre.
Eingabe	198 Bandspalten (Reflexion in %, 427–2.395 nm) sowie `AEZ` (2, 5–10) und `Month` (Mai bis Oktober); genutzt werden 131 Spektralbänder.
Verarbeitung	Interpolation einzelner Lücken, Standardisierung der Bänder, AEZ one-hot, Monat als Sinus/Kosinus und je ein Indikator für die 32 beobachteten AEZ-Monat-Zellen: 172 Merkmale. Alle Werte stammen aus dem Training.
Ausgabe	Eines der 23 beobachteten Crop-Stage-Paare, daher nie ein ungültiges Paar. Keine Wahrscheinlichkeit und keine Unsicherheitsangabe.
Training	Alle 5.589 bereinigten Zeilen aus `train.csv`; kein Validierungsanteil.

Die Hyperparameter wurden mit der 5-fach-CV im Trainingsanteil gewählt (BAcc kombiniert 0,864). Auf dem Holdout (1.118 Zeilen) erreicht das Modell die in Tabelle 4 genannten Werte. Die Endfassung nutzt auch diese Zeilen; ihre Leistung auf `test.csv` ist ohne Labels nicht messbar. AEZ-Monat-Indikatoren verbessern das Modell nur geringfügig (CV +0,005, Holdout +0,003).

Tabelle 4: Leistung auf dem Holdout (80/20-Split).

	BAcc Crop	BAcc Stage	BAcc kombiniert	Macro-F1 kombiniert	Samples-F1
Offizielles Modell	0,923	0,922	0,869	0,859	0,920

Grenzen und Risiken.

- Mehrere Ansätze wurden auf demselben Holdout verglichen; er ist keine unabhängige Abschlussprüfung.
- Das Modell hängt stark vom Kontext: Ohne `AEZ` und `Month` sinkt die CV-BAcc von 0,859 auf 0,787. Bei Gruppen-CV fällt die Referenz-SVM (ohne AEZ-Monat-Indikatoren) von 0,859 auf 0,378 (neue AEZ-Monat-Zelle), 0,421 (neuer Monat) und 0,284 (neue Region). `test.csv` liegt in bekannten Zellen; für neue Regionen oder Zeitpunkte ist das Modell nicht abgesichert.
- Die meisten Fehler sind Kulturfehler, vor allem Winterweizen zu Baumwolle und Sojabohne zu Mais, besonders in frühen Stadien. Seltene Klassen sind unsicher: `cotton|Harvest` hat 11 Trainingszeilen, Reis 93.
- Nicht beobachtete Paare können nie vorhergesagt werden. Nicht geprüft sind Kalibrierung, Ablehnung unbekannter Eingaben, Praxistests und echte Sentinel-2-Daten.

8 Fazit und Ausblick

Literatur

[1] Domänenprojekt 2 (2026). *Beschreibung Domänenprojekt 2, Vorabversion 2026/27; Kickoff-Folien zur Aufgabenbeschreibung.* Bereitgestellte Projektunterlagen.

[2] Mulla, D. J. (2013). Twenty five years of remote sensing in precision agriculture: Key advances and remaining knowledge gaps. *Biosystems Engineering*, 114(4), 358–371. https://doi.org/10.1016/j.biosystemseng.2012.08.009.

[3] NASA (2025). *Earth Observing-1.* NASA Earth Observatory. https://science.nasa.gov/earth/earth-observatory/earth-observing-1.

[4] Aneece, I. & Thenkabail, P. (2018). Accuracies achieved in classifying five leading world crop types and their growth stages using optimal Earth Observing-1 Hyperion hyperspectral narrowbands on Google Earth Engine. *Remote Sensing*, 10(12), 2027. https://doi.org/10.3390/rs10122027.

[5] Thenkabail, P. & Aneece, I. (2019). *Global Hyperspectral Imaging Spectral-library of Agricultural crops for Conterminous United States V001* [Datensatz]. NASA Land Processes Distributed Active Archive Center. https://doi.org/10.5067/COMMUNITY/GHISA/GHISACONUS.001.

A Ergänzende Ergebnisse und Reproduktion